09 tidyverse数据读取和初步查看

2026/3/30

写在前面：暂无：)

---

tidyverse的补充说明

- 下面的情况是出现了命名空间冲突（`dplyr`包里有个`filter`和`lag`函数，和`R` base中的函数重名了）：

```
✓ purrr     1.2.0
── Conflicts ──────────────────────────────────────────────────────────── tidyverse_conflicts() ──
✗ dplyr::filter() masks stats::filter()
✗ dplyr::lag()    masks stats::lag()
ℹ Use the conflicted package to force all conflicts to become errors
>
```

- “dplyr::filter() masks stats::filter()”意味着`dplyr`中的`filter`函数覆盖了`R` base中的`filter`，这种情况下，调用`filter`函数会指向`dplyr`中的函数，而不是基础包里的。
- 如果想用基础包里的函数，同时避免歧义，可以在调用时指定命名空间：

```
dplyr::filter()
stats::filter()
```

tidyverse数据读取

- 用下面这个函数来读取csv文件：

```
data <- read_csv('./data_case_day20.csv') # 来自于readr这个包
data_df <- read.csv('./data_case_day20.csv') # 来自于base R
```

- 读出来的数据略有差别：

```
Data
data                    200 obs. of 5 variables
  $ PID    : chr [1:200] "P001" "P002" "P003" "P004" ...
  $ pCR    : num [1:200] 1 0 1 0 1 1 1 1 1 1 ...
  $ Age    : num [1:200] 49.9 42.2 59.6 59.1 41.8 ...
  $ Stage  : chr [1:200] "I" "I" "III" "I" ...
  $ Subtype: chr [1:200] "HR+HER2+" "HR-HER2+" "HR+HER2+" "…
  - attr(*, "spec")=
   .. cols(
   ..   PID = col_character(),
   ..   pCR = col_double(),
   ..   Age = col_double(),
   ..   Stage = col_character(),
   ..   Subtype = col_character()
   .. )
  - attr(*, "problems")=<externalptr>
data_df                 200 obs. of 5 variables
  $ PID    : chr  "P001" "P002" "P003" "P004" ...
  $ pCR    : int  1 0 1 0 1 1 1 1 1 1 ...
  $ Age    : num  49.9 42.2 59.6 59.1 41.8 ...
  $ Stage  : chr  "I" "I" "III" "I" ...
  $ Subtype: chr  "HR+HER2+" "HR-HER2+" "HR+HER2+" "HR+HER2…
Values
  a                     int [1:20] 1 2 3 4 5 6 7 8 9 10 ...
```

- 利用 `class()` 函数判断两个变量的类型：

```
class(data)
class(data_df)
```

- 用 `read_csv()` 读出来的数据是一种混合数据格式（以兼容 `tidyverse` 的其他功能），而用 `read.csv()` 读出来的数据是一个数据框：

```
> class(data)
[1] "spec_tbl_df" "tbl_df"      "tbl"         "data.frame"
> class(data_df)
[1] "data.frame"
>
```

tidyverse数据查看

- 使用 `glimpse()` 函数来查看数据：

```
glimpse(data)
glimpse(data_df)
```

```
> glimpse(data)
Rows: 200
Columns: 5
$ PID     <chr> "P001", "P002", "P003", "P004", "P005", "P006", "P007"…
$ pCR     <dbl> 1, 0, 1, 0, 1, 1, 1, 1, 1, 1, 0, 0, 0, 1, 0, 1, 0, 1, …
$ Age     <dbl> 49.89178, 42.23368, 59.60960, 59.09749, 41.76520, 33.3…
$ Stage   <chr> "I", "I", "III", "I", "I", "III", "I", "II", "II", "II…
$ Subtype <chr> "HR+HER2+", "HR-HER2+", "HR+HER2+", "HR+HER2+", "TN", …
> glimpse(data_df)
Rows: 200
Columns: 5
$ PID     <chr> "P001", "P002", "P003", "P004", "P005", "P006", "P007"…
$ pCR     <int> 1, 0, 1, 0, 1, 1, 1, 1, 1, 1, 0, 0, 0, 1, 0, 1, 0, 1, …
$ Age     <dbl> 49.89178, 42.23368, 59.60960, 59.09749, 41.76520, 33.3…
$ Stage   <chr> "I", "I", "III", "I", "I", "III", "I", "II", "II", "II…
$ Subtype <chr> "HR+HER2+", "HR-HER2+", "HR+HER2+", "HR+HER2+", "TN", …
>
```

- UP主在这里提到了几个数据类型，`chr`（字符型）、`dbl`（双精度浮点数，你可以理解成一个非常精确的、带有小数点的数）和`int`（整形数，全是整数）。
- 尽管`tidyverse`和`R` base的函数很大程度上可以互相兼容，但还是推荐统一到一种上去。