01-2 logistic回归 数据准备

2026/4/3

写在前面：本节课偏操作，直接看视频就好😉

Tidyverse版本数据分析

- 豆知识：`Rmd`文件默认的路径是和这个文件同级的目录，和`R proj`不在同一个路径下。
- UP主介绍了一个新的函数，`everything()`。这个函数是`tidyselect/dplyr`里的列选择助手函数，核心作用是选中 数据框/tibble 的所有列，最常用于`select()`、`across()`等函数中，实现列重排、批量操作等。
- 又用到了另一个函数，`across()`。这个函数是批量对多列执行同一个函数（说起来有点绕，但你可以理解为，对选中的每一列，都按照传入的那个函数进行处理），基本语法如下；

  ```
  across(.cols, .fns, ..., .names = NULL)
  ```

  其中，
  - `.cols`：表示选哪些列（列名、数值列、匹配规则、`everything()`都能写）
  - `.fns`：表示要执行的函数（1个 / 多个，内置 / 自定义都行）
  - `.names`：自定义新列名格式
    这个函数有以下典型的**应用场景**：
  - summarise + across → **批量多列统计**，例如对所有数值指标算均值、标准差

    ```
    # 模拟临床数据
    df <- tibble(
    分组 = c("对照","治疗"),
    年龄 = c(55,60),
    血糖 = c(5.2,7.8),
    血压 = c(120,135)
    )

    # 所有数值列，批量算均值
    df %>%
    group_by(分组) %>%
    summarise(
        across(where(is.numeric), mean, na.rm = TRUE)
    )
    ```

- mutate + across → 批量多列改数据，例如对所有数值列标准化 / 取整 / 替换缺失

```
# 所有数值列四舍五入保留1位
df %>%
mutate(
    across(where(is.numeric), ~round(.x, 1))
)
```

- 多函数并行 + 自定义列名，例如一列同时算均值 + 方差，自动命名

```
df %>%
summarise(
    across(
    c(年龄,血糖),
    list(均值=mean, 标准差=sd),
    na.rm=TRUE,
    .names = "{.col}_{.fn}"
    )
)
```

- UP主写了一句很抽象的代码，我们来逐层解析：

```
data_analysis %>% summarise(across(everything(), ~ sum(is.na(.))))
```

  - 首先，管道符和summarise我们已经很熟悉了，就跳过了；
  - 从 `summarise()` 最内层看起，最内层是 `is.na(.)`，这里的 `.` 是占位符，语义是**当前处理的这一列**；
  - 往外跳出一层，`sum(is.na(.))` 的意思是，`is.na(.)` 返回一个bool向量，因为这个向量的内容本质上是0和1（0代表 `FALSE`，1代表 `TRUE`），所以可以求和；
  - 再往外跳出一层，`~sum(is.na(.))` 中，`~` 的语义是，**对每一XX，都进行某操作**。在这个函数里，它的意思就是，对于每一列，都进行求和操作；
  - **`~` + `.` 是一对常用的固定搭配**！它们是 `tidyverse` **匿名函数**的标准简写格式！语义是，"~ 对 . 做什么操作"。例如，

    ```
    df %>% mutate(新列 = 原列 * 2)
    # 等效于
    df %>% mutate(新列 = ~ . * 2)
    ```

    它的语义是，对于每一个（"~"）原列（"."），都做原列数值乘2的操作！
    - 那么，什么是**匿名函数**呢？一般来说，我们在定义一个函数的时候，会给这个函数起个名字，例如，

```
# 给函数起名：count_na
count_na <- function(x) {
    sum(is.na(x))
}
# 要用的时候：喊名字调用
count_na(iris$Sepal.Length)
```

- **匿名函数**就是，用完就扔、临时用一下、不用起名的函数！有点类似`python`中的lambda语法！例如，

```
# 完整版匿名函数
function(x){ sum(is.na(x)) }

# 简写版匿名函数（~ + .）
~ sum(is.na(.))
```

  - 再往外跳一层，`across(everything(), ~ sum(is.na(.)))`的意思是，先选中了所有列（通过`everything()`实现的，它也是`across()`这个函数第一个传入的参数），然后对每一列，都进行`~ sum(is.na(.))`。
- UP主又介绍了一个函数，`pivot_longer()`，它的作用是，把“很宽”的表格，拉长变成“长表格”。这里，“宽表”是指很多列（比如：血压 1、血压 2、血压 3、血糖 1、血糖 2…）的表，而“长表”是指只有两列的表，内容是“变量名 + 对应数值”。