02-1 logistic回归 批量单因素

2026/4/4

写在前面：暂无。

本课概览

- 目标：批量单因素回归，输出 OR、95%CI、P 值
- 核心内容：
  - 建立模型：glm(y ~ x, family = binomial())
  - 得到OR与置信区间
  - 批量建模
- 输出：单因素OR表

建立模型

- UP主介绍了一个函数，`glm()`。这个函数是**广义线性模型**，可以用它做二分类结局的 Logistic 回归。它的作用是，分析某个因素会不会影响结局（算出 OR 值、95% CI、P 值）。
  - 基本的格式是，

    ```
    glm(<结局> ~ <变量>, family = binomial(), data = <数据>)
    ```

    - `<结局>`：二分类变量（0/1，有效 / 无效）
    - `~`：“被谁影响” / “关于谁”
    - `<变量>`：你要分析的因素（性别、年龄、血糖、分期……）
    - `family = binomial()`：明确这是在做 Logistic 回归
    - `data`：你的数据
- 补充：什么是“binomial”?
  - binomial是指二项分布（Binomial Distribution），它的前提是独立同分布的伯努利试验（Bernoulli Trial），即
    - 单次试验只有两种互斥结果：成功（记为 1）/ 失败（记为 0）；
    - 每次试验成功的概率为固定值 $p(0 < p < 1)$
    - 各次试验相互独立
  - 若随机变量 Y 服从参数为 n, p 的二项分布，记为：
    $Y \sim \text{Binomial}(n, p)$

得到OR与置信区间

- 补充：什么是OR值？什么是P值？
  - OR值（比值比）：忽略数学定义，含义是，自变量每变1单位，阳性结局的优势（Odds）变成原来的多少倍。临床上的三段判定如下：
    - $OR > 1$：危险因素，X 越大，阳性结局概率越高
    - $OR = 1$：无关联，X 和结局没关系
    - $OR < 1$：保护因素，X 越大，阳性结局概率越低

      举例：
    - $OR = 2.3$：X 每升 1 级，发生阳性结局的优势是原来的 2.3 倍；
    - $OR = 0.6$：X 每升 1 级，发生优势只剩原来 60%（降低风险）。
  - P值是统计学假设检验，含义是若 H_0 真的成立，观测到当前 / 更极端数据的概率
    - $P < 0.05$：拒绝原假设，即有统计学关联，这个变量显著影响结局；
    - $P \geq 0.05$：不拒绝原假设，即现有数据下，看不出有明确关联。
- 分析结果通常有四列：

```
Coefficients:
                              Estimate Std. Error  z value    Pr(>|z|)
(Intercept)                  -2.803446   0.275350  -10.18   <2e-16 ***
data_analysis$AGE_AT_DIAGNOSIS  0.051543   0.004521   11.40   <2e-16 ***
```

  - 其中，`(Intercept)`这一行是没啥用的；
  - 一般在英文论文里，只需要报告OR值（需要对`Estimate`进一步操作，用`exp(Estimate)`）和`Pr(>|z|)`这两列。
  - 95%置信区间可以通过`Estimate`与`Std.`这两列计算出来（具体方法没讲，后文有更简单的函数调用方式）
- （操作说明）可以在数据可视化窗口中，点击下图所示的按钮，将数据提取式打出来：

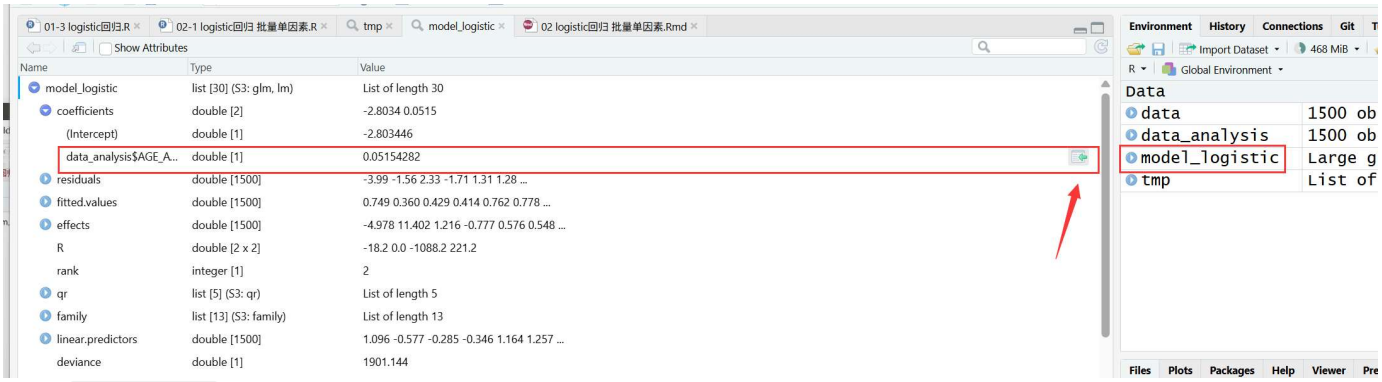

- 调用`confint()`函数计算置信区间（默认为95%置信区间）：

```
confint(model_logistic) # 计算estimate的置信区间
exp(confint(model_logistic)[2, ]) # 计算OR值的置信区间
```

批量建模

- UP主补充说，这节课的单因素分析是有**前提条件**的，必须所有参与分析的变量的都是二分变量或者连续型变量（这节课里的LATERALITY、ER_STATUS、HER2_STATUS、TUMOR_STAGE）
- 可以通过构建函数来批量建模，将已经写好的代码进行一定改造，让它适用于更广泛的场景。
- 但是，UP主实际上是用了循环来做这件事：

```
OR <- c(); OR_LCI = c(); OR_UCI = c()
# 批量建模
for (i in 3:7) {
data_x <- data_analysis[,i] # 需要先转换成向量
model_logistic <- glm(data_analysis$TreatmentOutcome ~ data_x, family = binomial())
## 计算OR值
OR[i-2] <- exp(model_logistic[["coefficients"]][2])
## 计算estimate的置信区间
confint(model_logistic)
## 计算OR值的置信区间
OR_LCI[i-2] <- exp(confint(model_logistic)[2, ][1])
OR_UCI[i-2] <- exp(confint(model_logistic)[2, ][2])
}
```

- 这里，UP主又介绍了一个函数，`colnames()`，它的功能是查看 / 修改 数据框的列名，
  - 查看：`colnames(数据)`
  - 修改：`colnames(数据) <- 新名字`
- 当然，我们也可以自己尝试写一个函数来处理：

```
OR_ <- c(); OR_LCI_ = c(); OR_UCI_ = c(); P_ <- c()
### 首先，定义一个函数
model_logistic_func <- function(data, idx) {
data_x <- data[,idx] # 转换成向量
model_logistic <- glm(data$TreatmentOutcome ~ data_x, family = binomial())
OR_[idx-2] <<- exp(model_logistic[["coefficients"]][2]) # 计算OR值
confint(model_logistic) # 计算estimate的置信区间
OR_LCI_[idx-2] <<- exp(confint(model_logistic)[2, ][1]) # 计算OR值的置信区间下界
OR_UCI_[idx-2] <<- exp(confint(model_logistic)[2, ][2]) # 计算OR值的置信区间上届
P_[idx-2] <<- summary(model_logistic)$coefficients[2, 4] # 计算P值
}

### 接下来，循环调用
for (i in 3:7) {
model_logistic_func(data_analysis, i)
}
results_func <- data.frame(Variable = colnames(data_analysis)[3:7],
                           OR_, OR_LCI_, OR_UCI_, P_)
```

- 注意，这里的`<<-`的含义是向**函数体外部赋值**，这其实背离的函数定义的初衷！理论上，应该让一个变量来接收这样的赋值！