02-2 logistic回归 批量单因素

2026/4/4

写在前面：暂无。

本课概览

- 用 `tidyverse` 风格重塑上节课的内容

建立模型

- UP主补充说，使用 `glm()` 分析之前，哪怕不去 `NA` 也是没问题的，因为这个函数会自动帮你忽略掉有NA的部分。
- 手工去掉 `NA` 可以用 `drop_na()` 这个函数：

```
data_analysis %>% drop_na()
```

  - 这个包是 `tidyr` 包的函数，专门用来删除含缺失值 `NA` 的行，它的基本用法如下：

```
# 删所有含 NA 的行
数据 %>% drop_na()

# 只在指定列里检查 NA，其他列不管
数据 %>% drop_na(列名1, 列名2)
```

- 这里又用到了一个函数， `map_dfr()` ，这个函数的功能是**循环+自动把结果拼成一个数据框**，可以理解为一种高级的 `for` 循环。它对很多列 / 很多变量做同一件事，每次返回一行 / 一个小数据框，最后自动 `rbind` 绑成一张大表。这也是它名字的来源（map=循环，也就是对每个元素做同一件事；d=data，输出数据结构；r=row，结果按行拼接；f=frame，最终变成数据框）
- 用到了一个函数， `as.formula()` ，它的作用是 把“字符串文字”变成 `R` 能识别的“公式公式（formula）”。
  - 对于这节课的例子， `glm(y ~ x, family = binomial())` 中的 `y ~ x` 就是一个公式（formula）。
  - 但是，如果你想在函数里、循环里动态生成公式，就必须用 `as.formula()`
  - 用代码来进一步说明：

```r
# 字符串（文字，R 看不懂这是公式）
str <- "TreatmentOutcome ~ age"

# 变成真正的公式
f <- as.formula(str)

# 现在可以直接丢进 glm 里用！
glm(f, family = binomial(), data = data_analysis)
```

- 豆知识：`paste`和`paste0`的区别在于，`paste0`粘贴中间没有连接符，`paste`默认为一个空格（之前的课程提到过哦）
- 又用到`broom`包中的一个函数，`tidy()`，这个函数的作用是把 glm / lm 模型的一堆杂乱结果，提取成标准表格格式，这个表格中包括系数、标准误、统计量、P 值，运行的结果会非常直观、漂亮：

```r
broom::tidy(fit, conf.int=T, exponentiate=T)
})
```

A tibble: 2 × 7

term <chr>	estimate <dbl>	std.error <dbl>	statistic <dbl>	p.value <dbl>	conf.low <dbl>	conf.high <dbl>
(Intercept)	0.06214753	0.287740650	-9.655376	4.664438e-22	0.03510879	0.1085313
AGE_AT_DIAGNOSIS	1.05118817	0.004712322	10.593741	3.185981e-26	1.04164192	1.0610729

2 rows

  - 这个函数有两个比较重要的参数，`conf.int`和`exponentiate`：

```r
tidy(
model,            # 你的 glm 模型
conf.int = TRUE,  # 输出 95% 置信区间
exponentiate = TRUE  # 自动 exp 变成 OR！不用自己算！
)
```

- 结果分析：
  - 下图左侧为UP主的运行结果，右侧为我们的运行结果：

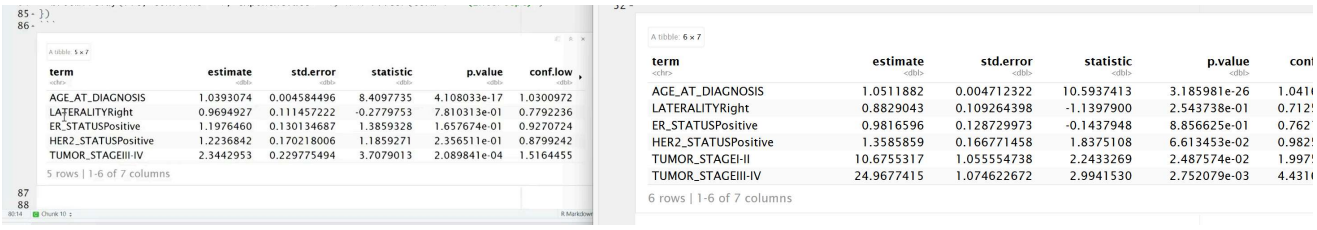

A tibble: 5 × 7

term	estimate	std.error	statistic	p.value	conf.low
AGE_AT_DIAGNOSIS	1.0393074	0.004584496	8.4097735	4.108033e-17	1.0300972
LATERALITYRight	0.9694927	0.111457222	-0.2779753	7.810313e-01	0.7792236
ER_STATUSPositive	1.1976460	0.130134687	1.3859328	1.657674e-01	0.9270724
HER2_STATUSPositive	1.2236842	0.170218006	1.1859271	2.356511e-01	0.8799242
TUMOR_STAGEIII-IV	2.3442953	0.229775494	3.7079013	2.089841e-04	1.5164455

5 rows | 1-6 of 7 columns

A tibble: 6 × 7

term	estimate	std.error	statistic	p.value	conf
AGE_AT_DIAGNOSIS	1.0511882	0.004712322	10.5937413	3.185981e-26	1.041
LATERALITYRight	0.8829043	0.109264398	-1.1397900	2.543738e-01	0.712
ER_STATUSPositive	0.9816596	0.128729973	-0.1437948	8.856625e-01	0.762
HER2_STATUSPositive	1.3585859	0.166771458	1.8375108	6.613453e-02	0.982
TUMOR_STAGEI-II	10.6755317	1.055554738	2.2433269	2.487574e-02	1.997
TUMOR_STAGEIII-IV	24.9677415	1.074622672	2.9941530	2.752079e-03	4.431

6 rows | 1-6 of 7 columns

  - Q：为什么有的变量右面被加了“Right”（比如“LATERALITYRight”），有的被加了“Positive”（比如“HER2_STATUSPositive”）？A：因为这几个都是二分变量，它们的基线是“Left” / “Negative”，这里显示的是相对于基线得到的OR值，所以这里出现了一个标注；如果是三变量，则会有两行（分别相对于基线的OR值）
  - Q：为什么我们这里是6行，UP主是7行？A：因为我们的“TUMOR_STAGE”变成了两行，这是因为原始数据中多了一个“0”的类型，所以这里成了上述三变量的情形，基线是“0”。

核心函数回顾

- 这次我们采用由外到内的方式来解析这个函数：

```
map_dfr(predictors, \(x){
    f <- as.formula(paste0("TreatmentOutcome ~ ", x))
    fit <- glm(f, family = binomial(), data=data_analysis)

    broom::tidy(fit, conf.int=T, exponentiate=T) %>% filter(term != "(Intercept)")
})
```

  - 最外层：`map_dfr(predictors, \(x){ ... })`。最外层的函数调用是`map_dfr()`，它的作用是对predictors里的每个元素循环执行函数，最后把所有结果按行拼成一个数据框。这个函数第一个传入参数是predictors，意思是要对这个向量进行处理；第二个传入参数是一个**匿名函数**（我们在第一节课中遇到过），它的写法是`\(x){ ... }`，它等价于`function(x){ ... }`，其中`x`表示当前循环到的自变量名（比如"age"）
  - 第一行：`f <- as.formula(paste0("TreatmentOutcome ~ ", x))`。最外层是调用了`as.formula()`这个函数，并把它的返回结果（一个`formula`类型的变量）赋值给变量f，如前所述，这个函数的作用是字符串转换成`R`能识别的公式对象，以解决循环里动态生成公式的问题。`as.formula()`的传入参数是一个`paste0`的返回结果，它返回的是一个字符串，就是将`TreatmentOutcome ~ `与`x`（对应的字符串）拼在一块。
  - 第二行：`fit <- glm(f, family = binomial(), data=data_analysis)`。这行比较简单，就是通过`glm()`函数建模，这里的传入参数`f`取代了之前的公式`data_analysis$TreatmentOutcome ~ data_x`，同时，因为指定了`data=data_analysis`，所以`$`之前的`data_analysis`也不用加了。
  - 第三行：`broom::tidy(fit, conf.int=T, exponentiate=T) %>% filter(term != "(Intercept)")`。管道符前半行的意思是用`broom::tidy()`函数对分析得到的结果`fit`进行整理，同时指定生成置信区间（`conf.int=T`），且计算指数的形式（`exponentiate=T`）；管道符后半的意思是，将名称为"(Intercept)"的行删除。