05 ROC曲线和AUC的计算

2026/4/5

写在前面：暂无。

本课概览

- 目标：绘制 ROC、计算 AUC、比较模型 AUC
- 核心内容：
  - 预测概率：`predict(model, type="response")`
  - ROC作图：`pROC::roc()`、`pROC::auc()`、画图与置信区间
  - 最佳截断点：`Youden index（coords(..., "best")）`
- 输出：ROC图

ROC绘制

- UP主一开始提到了一个“泛化性”的问题。我们即将绘制的ROC图是由1500例数据绘制的，它对这1500例数据的拟合程度一定很好，所以**不该在原数据的基础上判断建模效果**，而应该在独立的其他数据上进行验证。这就是在验证这个模型的**泛化性**。
  - 在计算机领域，也就是数据需要被划分成训练集/验证集/测试集。（前面的课程提到过，还记得吗？）
- 下面这行代码的意思是，对每一个样本都按照上节课画出来的nomogram图算一下概率，并把结果加到原来的数据框中：

```
# 预测概率
data_nom$pred_prob <- predict(fit_lrm, type = "fitted") # 概率
```

- 剩下的内容可以直接看视频🤭

补充：ROC与Youden Index

ROC

- ROC（Receiver Operating Characteristic，受试者工作特征曲线）是**评价二分类模型区分度**的金标准工具，横轴是**假阳性率**（FPR），纵轴是**真阳性率**（TPR），用来直观展示模型在不同截断点下的预测性能。

指标	公式	含义
真阳性率（TPR / Sensitivity 灵敏度）	`TP / (TP + FN)`	模型正确识别阳性样本的能力（漏诊率=1-TPR）
假阳性率（FPR / 1-Specificity 1-特异度）	`FP / (FP + TN)`	模型错误把阴性判为阳性的概率（误诊率=FPR）
AUC（Area Under the Curve，曲线下面积）	ROC 曲线与横轴围成的面积	模型区分度的量化指标，范围 0.5~1.0

- 几个特殊的情况：
  - **AUC=0.5**：模型完全无区分能力（和随机猜一样，对应代码里 `abline(a=0,b=1)` 的对角线）
  - **AUC接近1**：模型区分能力越强（临床研究中，AUC>0.7 为可接受，>0.8 为良好，>0.9 为优秀）

Youden Index

- Youden指数（J）是寻找最佳截断点（最佳阈值）的最常用指标，本质是**最大化正确分类的总概率**，平衡漏诊和误诊。
- Youden指数（J）的公式如下：

$$J = \text{Sensitivity（灵敏度）} + \text{Specificity（特异度）} - 1$$

- Q：为什么要找最佳截断点?
  - A：截断点太高：灵敏度低，漏诊多；截断点太低：特异度低，误诊多。
  - Youden 指数取最大值时，对应的截断点就是最优阈值，此时模型的整体分类性能最好。

举例

- 以我们在课上画的图为例：

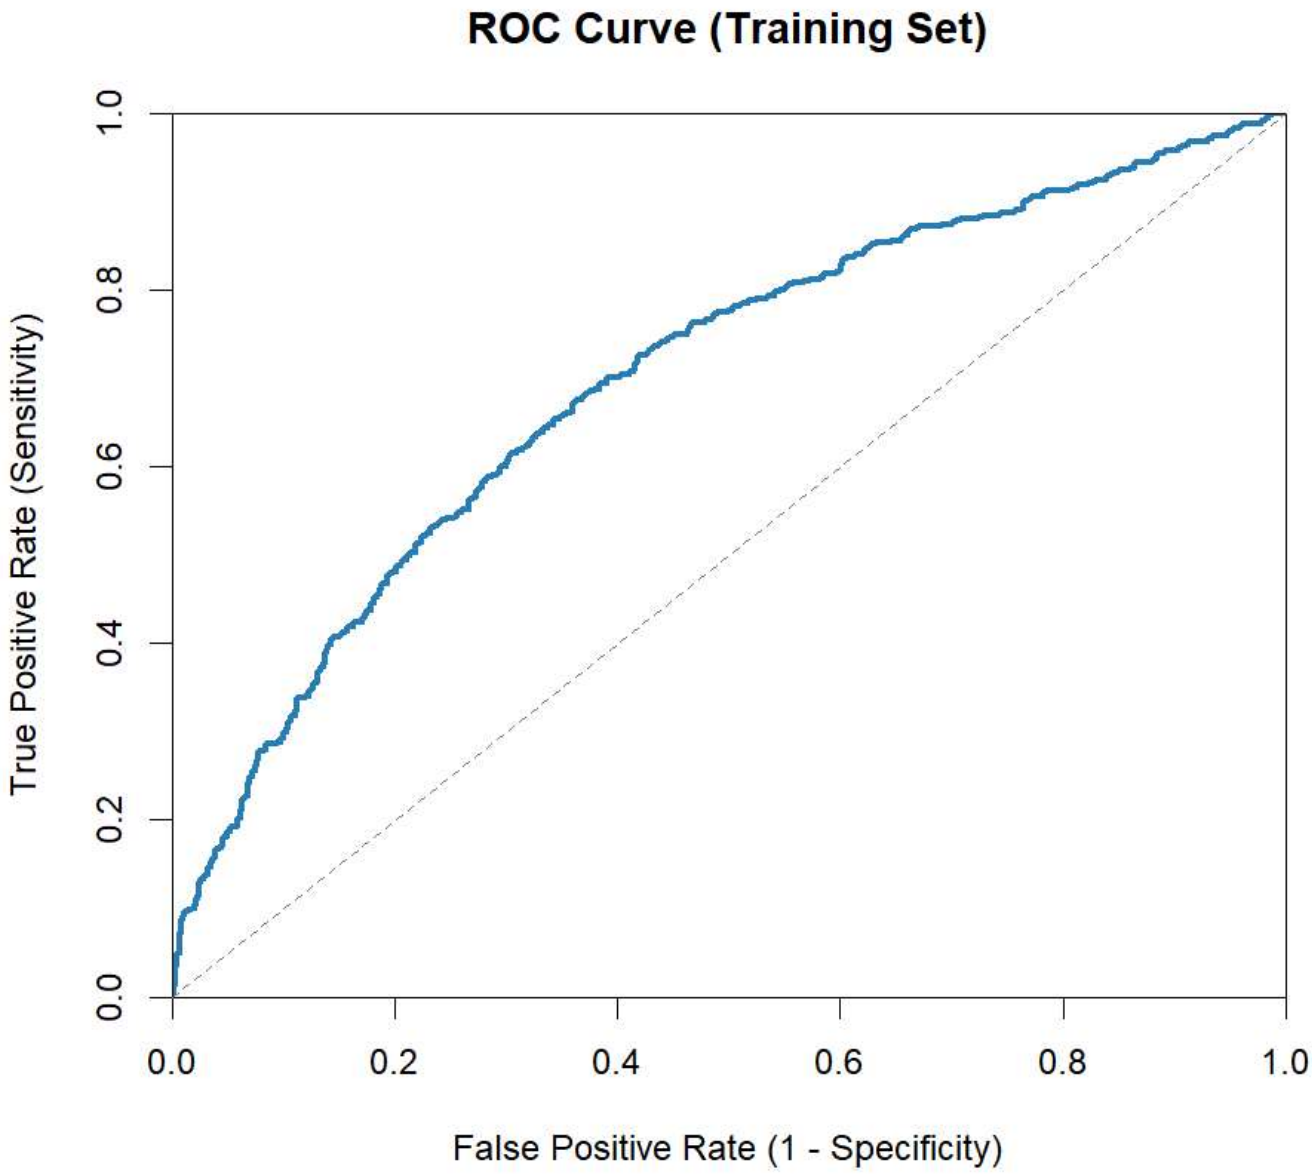

- 从这张图的基本结构来看，
  - **横轴（X 轴）**：False Positive Rate (1 - Specificity)，也就是假阳性率（FPR），代表「把阴性样本错判为阳性的比例」，数值越高，误诊越多。(它的计算公式是FP / (FP + TN))
  - **纵轴（Y 轴）**：True Positive Rate (Sensitivity)，也就是真阳性率（TPR / 灵敏度），代表「把阳性样本正确识别的比例」，数值越高，漏诊越少。（它的计算公式是TP / (TP + FN)）
  - **灰色虚线（对角线）**：y=x，代表完全随机猜测的性能（AUC=0.5），是模型的及格线（落到这条曲线下方，模型就不及格了，因为模型预测的还不如随机猜的，都能成为反指了🤣）
  - **蓝色实线**：你的模型的 ROC 曲线，曲线越远离对角线、越靠近左上角，模型区分能力越强。
- ROC曲线是什么？
  - ROC 曲线是模型在所有可能的截断点（阈值）下，灵敏度（y轴）和特异度（1-x）的组合轨迹。
  - 对于二分类模型（比如你的治疗结局预测模型），我们需要一个**阈值**来判断样本是阳性 / 阴性（比如预测概率≥0.5判为阳性）。不同的阈值对应不同的灵敏度 / 特异度：阈值越低，灵敏度越高（漏诊少）、特异度越低（误诊多），**对应ROC曲线右侧**；阈值越高，反之。
  - ROC曲线把所有阈值下的 (FPR, TPR) 点连起来，直观展示了模型在“漏诊”和“误诊”之间的权衡。

- **人话解读**：如果一个模型判别很宽松，有一点患病的苗头就给判成阳性（极端一点，无论如何，全部判成阳性），那这个模型的真阳性率一定为1（此时FN=0，因为不会有假阴性，全判成阳性了），假阳性率也一定为1（此时TN=0，因为把所有的阴性案例都判成阳性了），对应了ROC曲线上(1, 1)这个点；反之，如果这个模型的判别很严格，必须证据非常非常显著才判别成阳性（极端一点，全部判成阴性），那这个模型的真阳性率一定为0（此时TP=0，因为全判成阴性了，没有阳性判别了），假阳性率也为0（因为FP=0），对应了ROC曲线上(0, 0)这个点。我们把ROC曲线画出来，就是想找一个**最佳的权衡阈值**，让误诊（假阳）和漏诊（假阴）之间可以权衡。

- AUC是什么？
  - AUC（Area Under the Curve，曲线下面积），就是 ROC 曲线与横轴（X 轴）围成的面积，是模型区分度的量化金标准。
  - 它的取值范围为0.5 ~ 1.0（为什么不会小于0.5？反向预测！）。
  - 在这张图中，蓝色曲线下的面积就是AUC。显然，它是要大于0.5的！
- Youden 指数是什么？
  - Youden指数的最大值，对应的就是最优阈值：此时模型的漏诊和误诊达到最优平衡，整体分类性能最好。
  - 在这张图里，你可以把 ROC 曲线上的每一个点，都对应一个 Youden 指数值。曲线上最靠近左上角的点，就是 Youden 指数最大的点，对应的阈值就是最佳截断点。
  - Youden 指数的核心是平衡漏诊和误诊，如果是癌症筛查等场景，会优先提高灵敏度（降低漏诊），可以手动调整阈值；而常规临床决策，Youden 指数的最优阈值是最均衡的选择。