02 模型开发的准备工作

2026/4/7

写在前面：这一章会涉及很多的临床相关的知识，我就只记录少说话了 🫣

概览

模型开发的准备工作

1. 数据来源
2. 研究对象的选择
3. 数据收集
4. 数据预处理

数据来源

1. 公开数据集
   - 美国国家癌症研究所（NCI）基因组数据 Commons（Genomic Data Commons, GDC）的官方数据门户：https://portal.gdc.cancer.gov/
     - 用于公开、标准化地存储和共享癌症相关的基因组、临床和病理数据，是肿瘤基因组学研究（如 TCGA 项目）的核心数据平台。
   - cBioPortal： https://www.cbioportal.org/
     - 这是一个开源的癌症基因组学数据可视化与分析平台，整合了 TCGA、ICGC 等多个大型癌症研究项目的多组学数据（基因组、转录组、蛋白组等），可以快速进行肿瘤分子特征、生存分析、通路富集等研究，是肿瘤生物信息学和临床转化研究的常用工具
   - NCBI GEO：ncbi.nlm.nih.gov/geo/
     - GEO 是由美国国立生物技术信息中心（NCBI）维护的全球最大的公共基因表达数据库之一，收录了大量微阵列、RNA-seq 等高通量测序数据，是生物信息学研究中获取基因表达谱、临床表型关联数据的核心资源库。
   - 在使用数据之前需要注意数据来源的控制政策，避免使用未被授权的数据：

Implementation Update: Enhancing Security Measures for NIH Controlled-Access Data

Notice Number:
NOT-OD-25-083

Key Dates

Release Date:	April 2, 2025

Related Announcements

- **September 24, 2025** – NIH Policy on Enhancing Security Measures for Human Biospecimens. See notice NOT-OD-25-160
- **September 24, 2025** – Required Security and Operational Standards for NIH Controlled-Access Data Repositories. See notice NOT-OD-25-159
- **July 25, 2024** – Implementation Update for Data Management and Access Practices Under the Genomic Data Sharing Policy. See notice NOT-OD-24-157
- **August 27, 2014** – NIH Genomic Data Sharing Policy. See notice NOT-OD-14-124

Issued by

Office of The Director, National Institutes of Health (OD)

Purpose

NIH takes oversight of security including confidentiality, integrity, and availability of participant data very seriously. In support of recent security directives, NIH is implementing a technical update to enhance security measures focused on protecting data provided by NIH Controlled-Access Data Repositories.

Specifically, as of April 4, 2025, NIH is prohibiting access to NIH Controlled-Access Data Repositories and associated data by institutions located in countries of concern. These countries include China (including Hong Kong and Macau), Russia, Iran, North Korea, Cuba, and Venezuela, consistent with EO 14117 and 28 CFR Part 202 "Preventing Access to U.S. Sensitive Personal Data and Government-Related Data by Countries of Concern or Covered Persons.

2. 自己收集
   - 电子病历 + 电话随访
   - 生物标本测序（组学研究）

研究对象的选择

- 标准1：符合课题设计
- 标准2：样本量足够
  - 除了上节课提到的文章里的样本量估算方法，还提到了一个“十样本原则”(每想纳入一个变量，就要有10个阳性样本的支撑)
- 标准3：抽样合理

数据收集

1. 结局变量的选择（PICO中的“O”）
   - 从临床角度
     - 致死事件（推荐）
       - 例如肿瘤研究中的overall survival（全因死亡）
     - 非致死事件
       - 例如肿瘤复发、肿瘤进展，但这个因素有主观判断因素在内
       - 还有一些和患者的主观感受相关，但是认可度很低（因为操作空间比较大）
   - 从统计学角度 (模型选择相关)
     - 连续型变量
     - 二分类变量（推荐）
     - 多分类变量
       - 缺点是，模型选择不方便，且临床认可度较低
     - 时间事件变量（推荐）

        - 既有时间又有事件的二维变量，例如，OS, PFS, DFS
    - 题外话：临床预测模型要符合统计学规律，但是更要符合临床医生的共识。
2. 预测因子 (自变量) 的选择
    - 潜在预测因子的选择方法
        - **文献回顾**
        - **专家经验**
            - 就算最终不纳入模型，最起码要做一下
        - **理论知识**
    - 潜在预测因子的精简（EPV=10），以下是可以考虑精简的原因：
        - 预测能力
        - 成本
            - 这里举了一个lasso回归的例子，lasso回归可以筛选出比较相关的因子，需要在这些因子的基础上再建模。
        - 不合理（时间不合理，测量不准确，标准不统一）

数据预处理

1. 离群值处理

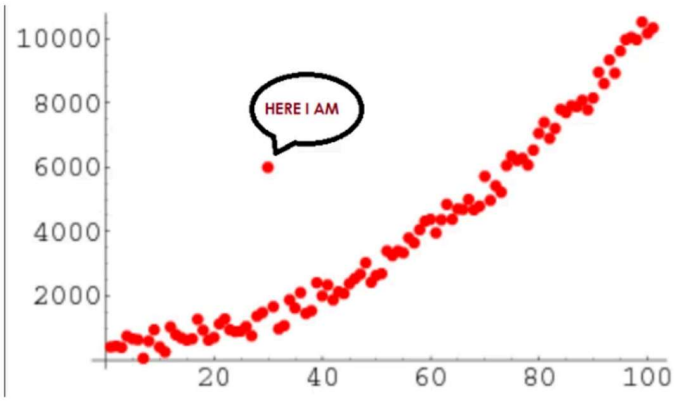

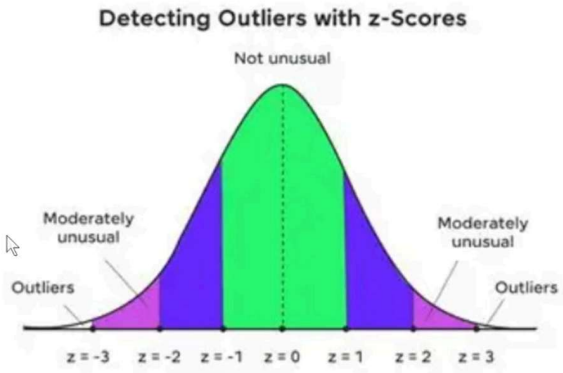

    - 在建立模型的时候可以删除离群值，在验证模型的时候不能删除
    - 但是在删除之前还是需要double-check，确定是算错了还是本来就这样
2. 缺失值处理
    - 完全数据法 – 删（即删除含缺失值的样本，完整病例分析）
    - 虚拟变量 – 不推荐
        - 新增一类“缺失”
    - 填补（用得比较多）
        - 统计量填充（均值、中位数、众数）
            - 新手推荐
            - 符合正态分布可以用均值填补，否则可以用中位数填补；分类变量可以用众数填补
        - 末次观察填补（纵向数据，即 LOCF 法）
        - K 近邻填补
        - 多重填补
        - 机器学习模型

- 题外话：缺失值有很多种类型，比如随机缺失，非随机缺失等。

3. 数据重新赋值

N分期	N分期
N0	N0
N0	N0
N0	N0
N0	N0
N0	N0
N0	N0
N0	N0
N0	N0
N0	N0
N0	N0
N0	N0
N0	N0
N0	N0
N1	N1-N3
N1	N1-N3
N2	N1-N3
N3	N1-N3
N3	N1-N3

组织类型	腺癌	鳞癌	小细胞
腺癌	1	0	0
腺癌	1	0	0
腺癌	1	0	0
腺癌	1	0	0
腺癌	1	0	0
腺癌	1	0	0
鳞癌	0	1	0
鳞癌	0	1	0
鳞癌	0	1	0
鳞癌	0	1	0
鳞癌	0	1	0
小细胞	0	0	1
小细胞	0	0	1
小细胞	0	0	1
小细胞	0	0	1
小细胞	0	0	1
小细胞	0	0	1

ER	PR	HR
1	1	1
1	1	1
1	1	1
1	1	1
1	1	1
1	1	1
0	1	1
1	1	1
1	1	1
1	1	1
1	1	1
1	1	1
1	1	1
1	0	1
1	1	1
1	1	1
0	0	0

- 二分转换
  - 将多分类合并成二分类；
  - 例如上图中左侧的例子，可以将N0分成一类，N1-N3分成一类；
- 哑变量
  - 例如上图中中间的例子，`R`语言会自动把你的变量用数字编码（例如one-hot编码）。
  - 在上图的例子里，其实知道两列的结果就能推知第三列。
- 合并变量

4. 数据格式整理- 宽格式

- 注意在数据中排除中文（包括汉字与字符）
- 推荐按照下面的方式组织临床数据：

ID	Outcome	X1	X2	X3	X4	X5
P001						
P002						
P003						
P004						
P005						

- 如果是组学的研究，则可以这么整理：

Gene	ID1	ID2	ID3	ID4	ID5	ID6
Gene 1						
Gene 2						
Gene 3						
Gene 4						
Gene 5						
Gene 6						

- 还有一种“长格式”，主要是作图用的，平时不要这么做。