03 预测模型的选择

2026/4/7

写在前面：这一章会涉及很多的临床相关的知识，我就只记录少说话了🤐

模型选择 - 概览

医学中的模型选择主要要看你的结局变量是什么类型，其中下面的1 连续变量用得比较少，2、3比较多。

1. Outcome 为连续变量
   - 线性回归模型 – 正态分布
   - 广义线性回归模型 – 其他分布
2. Outcome 为分类变量
   - **二分类 – Logistic 回归**
     - 是传统方法中用得最多的一类。
   - 多分类 – 变种 Logistic 回归
     - 不建议，一般是把多分类合并成二分类
3. Outcome 为时间 - 事件变量（Time to Event）
   - **无竞争风险 – Cox 回归**
   - 有竞争风险 – Fine-Gray 模型

- 机器学习 vs 传统模型

线性回归模型

- 临床建模适用条件 (弱于 LINE 假定)
  - LINE假定是经典线性回归的严格假设，Linear（线性关系）、Independent（独立性）、Normal（正态分布）、Equal variance（等方差）。在临床上，是将LINE的四个严格标准转换成了下列三个弱标准：
  i. 因变量对称分布
  ii. 预测因子没有强相关性
  iii. 残差无明显趋势
- 举了一个身高预测的例子
  - lm_model = lm(Y ~ H_father + H_mother + Fee)
  - $Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon$
    - ε是残差，基本上看到这个残差出现就知道用的是最小二乘法

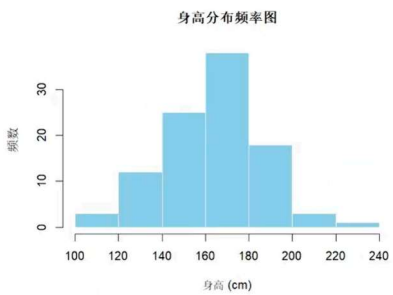

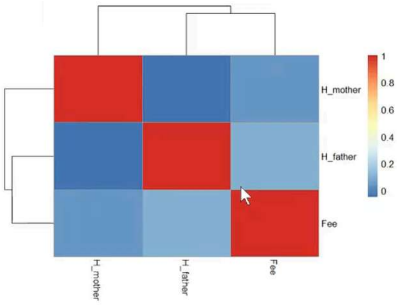

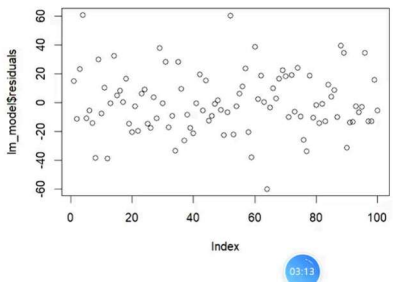

广义线性模型

- 多元线性回归模型（通用形式）：$Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \beta_i X_i + \varepsilon$
- 对数变换后的线性回归模型：$\log(Y) = \alpha + \beta_1 X_1 + \beta_2 X_2 + \beta_i X_i + \varepsilon$
- 举了一个因变量明显不对称（因而不满足线性回归模型的要求，就不能用线性回归）的例子：

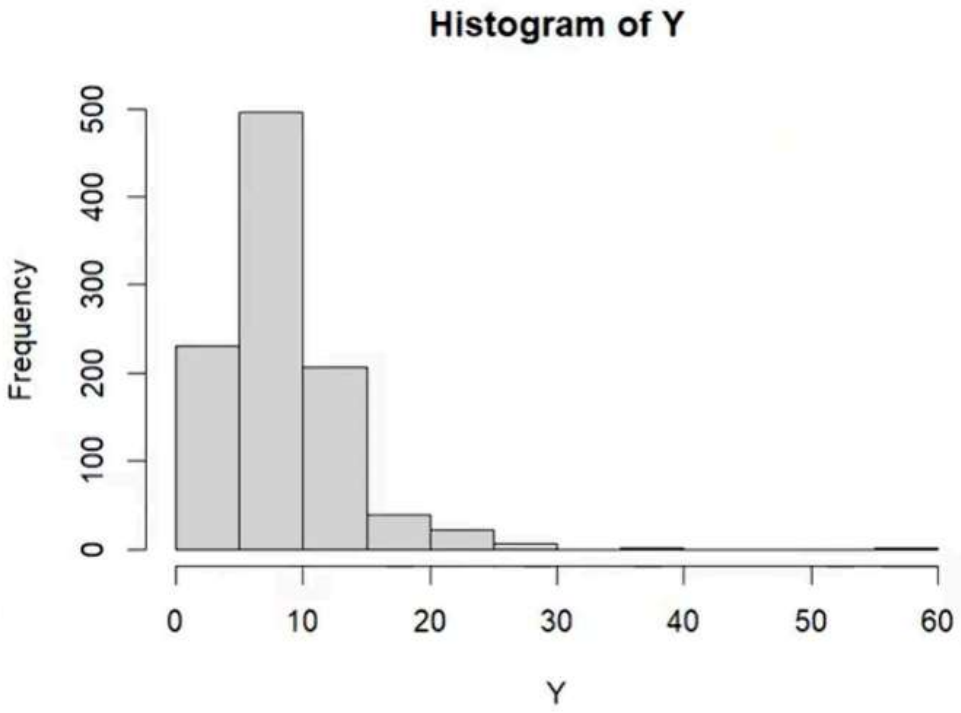

- 此时，对Y取对数，它的分布就对称了：

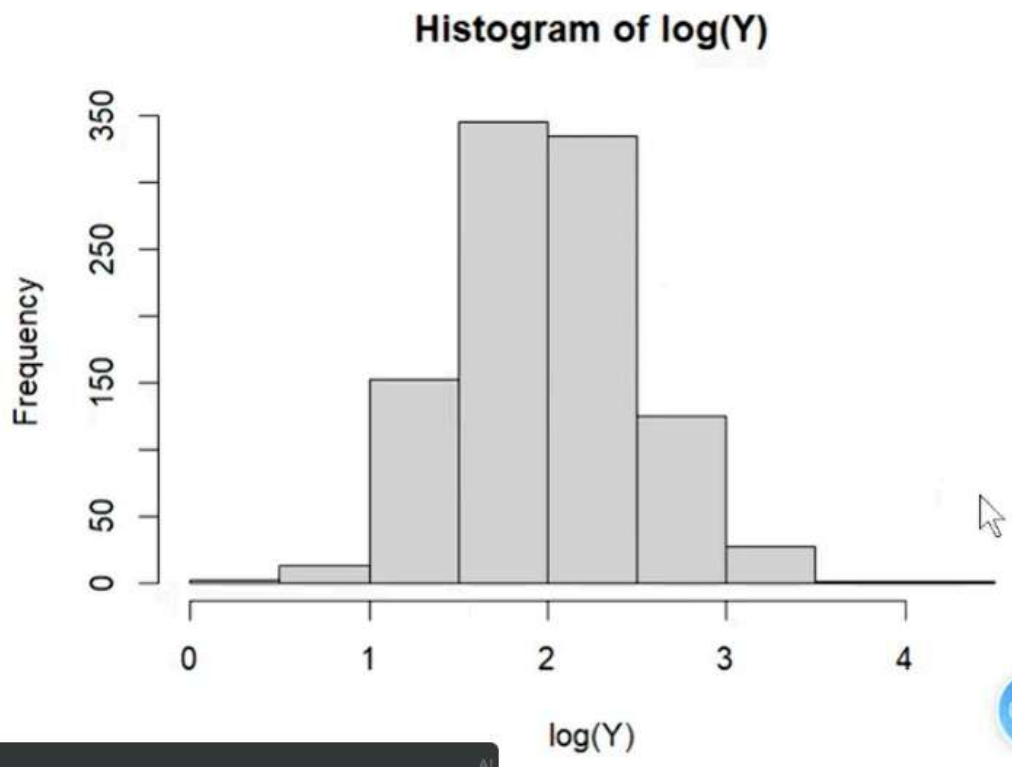

- 此时，把取完对数的Y，即$\log(Y)$视为因变量，就可以用线性回归模型了（因此，这里是“广义”线性模型）

Logistic回归

- Logistic回归的“Logistic”是一个自造词，指的其实就是$\ln\left(\frac{P(Y=1)}{1-P(Y=1)}\right)$
- Logistic 回归的对数似然比（logit）形式

$$\ln\left(\frac{P(Y=1)}{1-P(Y=1)}\right)=\alpha+\beta_1X_1+\beta_2X_2+\beta_iX_i$$

  - logit 变换形式：对事件发生的 odds（优势比，P/(1−P)）取自然对数，建立与自变量的线性关系，是模型估计的核心形式。
  - 注意，这里没有ε，说明不是通过最小二乘法优化。（实际上是用的极大似然法估计的）
- Logistic 回归的概率形式（Sigmoid 函数）

$$P(Y=1)=\frac{\exp(\alpha+\beta_1X_1+\beta_2X_2+\beta_iX_i)}{1+\exp(\alpha+\beta_1X_1+\beta_2X_2+\beta_iX_i)},\quad P(Y=0)=\frac{1}{1+\exp(\alpha+\beta_1X_1+\beta_2X_2+\beta_iX_i)}$$

  - 概率形式：通过 Sigmoid 函数将线性预测值映射到[0,1]区间，得到事件发生概率P(Y=1)，同时给出未发生事件的概率P(Y=0)
- 符号说明：
  - $Y=1$：事件发生（阳性结局），$Y=0$：事件未发生（阴性结局）
  - $P(Y=1)$：事件发生的概率
  - α：截距项
  - $\beta_1,\beta_2,...,\beta_i$：各自变量的回归系数（对应 OR 值的对数）
  - $X_1,X_2,...,X_i$：预测因子（自变量）
  - $\exp(\cdot)$：指数函数，用于将 logit 值转换回概率 / 优势比
- 举了一个抽烟和肺癌的例子（这个例子在视频的10:00，如果没有听懂可以回看）：

	X = 1 抽烟	X = 0 不抽烟
Y = 1 肺癌	a	c
Y = 0 无肺癌	b	d

$$OR=\frac{a/b}{c/d}=\frac{\exp\left(\ln\left(\frac{P(Y=1)}{1-P(Y=1)}\right)\middle|X=1\right)}{\exp\left(\ln\left(\frac{P(Y=1)}{1-P(Y=1)}\right)\middle|X=0\right)}=\frac{\exp(\alpha+\beta)}{\exp(\alpha)}=\exp(\beta)$$

  - 这是Logistic 回归中优势比（Odds Ratio, OR）的推导公式。
  - （SXS）这里的计算方式对你来说应该不是很重要，但是它能解释为什么之前第三章中，需要对estimate取一个指数才能得到OR值。这里的数学推导看一看就行，重要的是你会用，而不是具体的数学原理。

Cox回归

- UP主说，Cox回归也是类似于广义线性回归（不过更广义一些，形式和之前的线性回归差得更远）。
- 在医学中，**依然不关心它的风险值，而是关心它的风险比**，即每个自变量变动一个单位，风险单位会跟着变动多少。在医学中，常报告它的HR值（下面第5条）。
- 核心模型公式：

$$h(t,X)=h_0(t)exp(\beta_1X_1+\beta_2X_2+\beta_iX_i)$$

1. 生存函数：具有变量 $X=(X_1,X_2,...,X_m)$ 的观察对象的生存时间 T 大于某时刻 t 的概率，

$$S(t,X)=P(T>t,X)$$

   称为生存函数。生存函数 $S(t,X)$ 又称为累积生存率。
2. 死亡函数：具有变量 X 的观察对象的生存时间 T 不大于某时刻 t 的概率，

$$F(t,X)=P(T\le t,X)$$

   称为死亡函数。死亡函数 $F(t,X)$ 的实际意义是当观察随访到 t 时刻的累积死亡率。
3. 死亡密度函数：具有变量 X 的观察对象在某时刻 t 的瞬时死亡率，称为死亡密度函数。

$$f(t,X)=\lim_{\Delta t\to 0}\frac{P(t<T\le t+\Delta t,X)}{\Delta t}=F'(t,X)$$

4. 危险率 (风险) 函数：具有变量 X，且生存时间已达到 t 的观察对象在时刻 t 的瞬时死亡率，

$$h(t,X)=\lim_{\Delta t\to 0}\frac{P(t<T\le t+\Delta t|T\ge t,X)}{\Delta t}=\frac{f(t,X)}{S(t,X)}$$

称为危险率函数。危险率函数 $h(t, X)$ 实际上是一个条件瞬间死亡率。

5. 风险比（hazard ratio, HR）：

$$HR = \frac{h(t, X=1)}{h(t, X=0)} = \frac{\exp(\beta)}{\exp(0)} = \exp(\beta)$$

机器学习

模型概览

- 正则化技术 (岭回归、LASSO 回归、弹性网络)
  - 最常见。这三者都是对自变量系数进行一定惩罚（LASSO回归可以把自变量系数归到0）。
  - LASSO回归非常“神奇”，可以套在许多线性回归方法之后，只是在现有的方法上进行优化。听UP主的意思，LASSO回归更像是一种提高模型泛化性的技术。
- 支持向量机
- 朴素贝叶斯
- 集成方法 (随机森林、XGBoost)
- 神经网络
  - 上述四种都是传统的机器学习方法，神经网络是机器学习下的一个分支，深度学习。

优缺点

- 优点
  i. 对数据的要求灵活
    - 对分布要求低
    - 输入维度高
    - 可输入图像
  ii. 模型精度更高
    - 自动学习特征
    - 非线性关系
- 缺点
  i. 稳定性差
    - 随机性
    - 容易过拟合
  ii. 速度慢
    - 其实不是大问题；现在的GPU训练模型其实非常快（除了医学影像类的，其实做个分类做个预测训练起来没多慢）；
    - 还提到了一个随机种子的问题，这个确实有一定影响，但是哪怕在深度学习领域，大家做个3-5个也差不多了；
  iii. 可解释性低