04 变量的筛选和模型呈现

2026/4/8

写在前面：这一章会涉及很多的临床相关的知识，我就只记录少说话了🤐

变量的筛选

为什么需要筛选预测因子

1. 正样本不足
    - 比如：治疗反应率为50%

	样本1	样本2	……
基因1			
基因2			
基因3			
……			
基因20000			

$$N = \frac{20000 * 10}{50\%} = 400{,}000$$

	样本1	样本2	……
基因1			
基因2			
基因3			
……			
基因20			

$$N = \frac{20 * 10}{50\%} = 400$$

2. 共线性
    - 有的预测因子之间可能高度相似 / 高度相关：

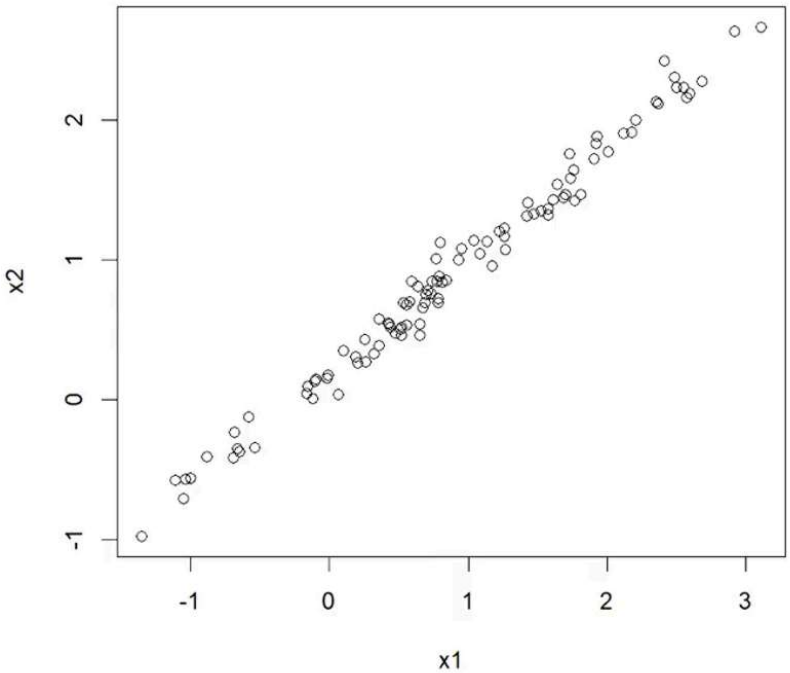

$$y \sim 5x_1 + 6$$

$$y \sim 5x_2 + 6$$

$$y \sim x_1 + 4x_2 + 6$$

$$y \sim 2x_1 + 3x_2 + 6$$

$$y \sim 3x_1 + 2x_2 + 6$$

$$y \sim 4x_1 + x_2 + 6$$

预测因子筛选的原则

1. 专家意见为主，统计显著性为辅
    - 不能脱离临床。
2. 因果关系为主，关联关系为辅
    - 这条其实不是很重要，因为不太关心具体是因果关系还是关联关系。
    - 在生物学逻辑上认为有因果关系即可，不用非要做因果分析。
3. 原有模型中的预测因子为主，新的预测因子为辅
4. 临床可获得为主，预测效能为辅

预测因子的筛选框架

1. 去除缺失较多的预测因子（>20%）
    - 难以获得的预测因子一般就不要了（>15%缺失），特别重要的可以放宽到20%。
    - 还要注意缺失比例比部分变量比例还高的情况。
2. 去除信息较少的预测因子（取值单一）
    - 比如下表中的变量2，它带来的信息量太少了：

患者ID	变量1	变量2
P001	A	A
P002	A	A
P003	B	A
P004	C	A
P005	B	A
P006	C	A
P007	C	B

3. 基于单因素分析筛选变量
    - UP主提到，单因素显著和多因素显著没有直接的联系，但是大家都这么做，所以可以考虑跟着这么做🤯

	Univariate Cox regression model		Multivariate Cox regression model	
	HR (95% CI)	*p*-value	HR (95% CI)	*p*-value
Age	0.98 (0.94–1.01)	0.147	0.88 (0.78–1.00)	0.052
AJCC 7th stage	1.19 (0.40–3.50)	0.756		
Tumor grade	5.11 (1.67–15.60)	0.004	100.52 (1.33–7570.21)	0.037
N stage	0.92 (0.28–3.04)	0.891		
ER	0.39 (0.11–1.46)	0.162	0.51 (0.03–8.94)	0.648
PR	1.47 (0.32–6.64)	0.618		
HER2	2.29 (0.49–10.64)	0.290		
Ki-67 levels	57.70 (6.36–523.40)	<0.001	31.47 (1.05–945.82)	0.047
CgA	0.40 (0.10–1.58)	0.187	0.04 (0.001–1.12)	0.058
Surgery	0.71 (0.16–3.22)	0.658		
Radiotherapy	2.80 (0.90–8.70)	0.074	0.04 (0.001–1.77)	0.096
Endocrine therapy	0.72 (0.22–2.36)	0.588		
Chemotherapy	1.52 (0.47–4.95)	0.486		

4. 子集筛选法 - 以最优子集法举例
   - 比如总共有5个变量，共有$2^5 = 32$种可能（其实就是枚举法😵）

组合1	组合2	组合3	……	最佳组合
空			……	
x1	*x2*	*x3*	……	*x2*
x1x2	*x1x2*	*x1x3*	……	*x1x3*
x1x2x3	*x1x2x4*	*x1x2x5*	……	*x3x4x5*
x1x2x3x4	*x1x2x3x5*	*x1x2x4x5*	……	*x2x3x4x5*
x1x2x3x4x5			……	*x1x2x3x4x5*
最佳组合				*x3x4x5*

5. 正则化技术和其他机器学习技术
   - 还有随机森林、XGBoost、神经网络。

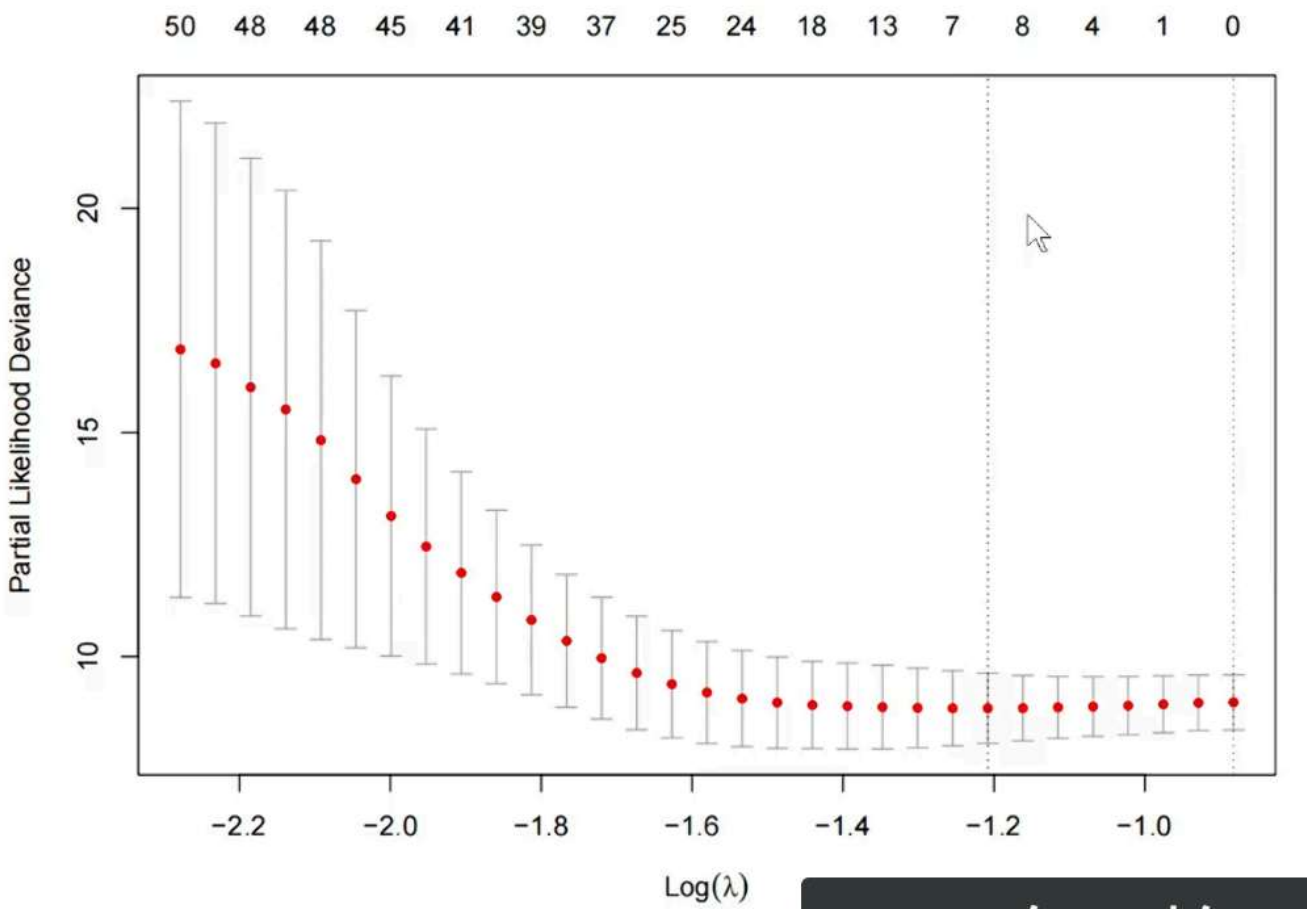

- 补充：**正则化**（Regularization）
  - 正则化就是在模型训练时加一个**惩罚项**，防止模型把噪声也学进去，从而**避免过拟合**，让模型更稳定、泛化能力更强。
  - 在原来的损失函数后面，加上对模型系数大小的惩罚：

$$\text{新损失} = \text{原损失} + \lambda \cdot \text{惩罚项}$$

    - λ越大，惩罚越强，系数会被压得越小
    - $\lambda = 0$ 就是普通回归，没有正则化
  - 常用的正则项包括：
    - L1 正则（LASSO），**惩罚系数的绝对值和**，能把不重要变量的系数直接压到 0，实现自动特征选择。
    - L2 正则（Ridge / 岭回归），**惩罚系数的平方和**，让所有系数变小但不为 0，主要解决**多重共线性**，让模型更稳定。
    - Elastic Net（弹性网络），L1 + L2 结合，既可以特征选择，又能处理强共线性。
- 补充：**随机森林**（Random Forest）
  - 随机森林是一种**集成学习**（ensemble learning，“三个臭皮匠，顶个诸葛亮”）算法，通过**构建多棵决策树并让它们共同投票**，得到更稳定、更准确的预测结果。
  - 核心思想：
    - Bootstrap 抽样：从原始数据中有放回地随机抽取多组数据集
    - 随机特征选择：每棵树训练时只随机选用部分特征
    - 多树投票：
      - 分类：多数树的结果作为最终类别
      - 回归：多棵树结果取平均

    - 优点是不容易过拟合，能处理非线性、交互效应，可给出特征重要性，对异常值、缺失值相对鲁棒；
    - 缺点是可解释性不如逻辑回归、Cox，训练高维数据时速度较慢，无法像回归模型直接给出 OR/HR。
- 补充：**XGBoost**
    - XGBoost（Extreme Gradient Boosting，极端梯度提升）是梯度提升树（GBDT）的优化升级版，属于集成学习中的 Boosting 算法。
    - 核心思想：
        - Boosting 核心逻辑：串行训练多棵决策树，每一棵新树都专门纠正前一棵树的残差（预测误差），最终将所有树的预测结果加权求和，得到最终输出。
        - 核心优化（具体的实现，不重要！）：二阶泰勒展开损失函数，提升拟合精度；加入正则化项（L1/L2 惩罚），有效防止过拟合；支持并行计算、缺失值自动处理、剪枝优化，训练效率和稳定性大幅提。
    - 优点：
        - 预测精度高，对非线性、交互效应的拟合能力极强；
        - 内置正则化，过拟合风险远低于普通决策树；
        - 支持特征重要性评估，可解释性优于随机森林；
        - 对数据分布要求低，兼容高维、含缺失值的临床数据；
        - 训练速度快，支持并行计算。
    - 缺点：
        - 超参数较多，调参复杂度高于传统统计模型；
        - 可解释性仍弱于 Logistic 回归、Cox 回归等线性模型
        - 对极端异常值敏感，需提前做数据预处理。
- 补充：**神经网络**（Neural Network）

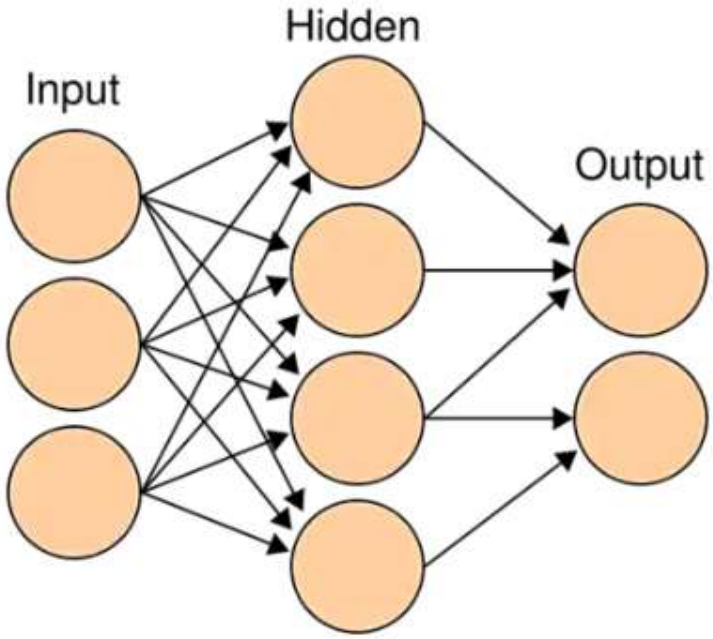

    - Dropout：让一些“神经元”随机失活，达到降低过拟合的目的。

模型呈现

1. 数学公式

- 怎么真有人把公式直接怼到文章里。。。

Model establishment based on apoptosis gene

The overall flow of the article is shown in Fig. 1: through the MSigDB database, we obtained 161 apoptosis-related genes. The apoptotic gene expression data of 406 TCGA patients with clinical data and 165 GEO (GSE13507) patients were extracted. TCGA is used to establish the model, and the GSE13507 cohort is used as the test group to verify the model. In the establishment of the model, Univariate Cox regression was used to screen out 28 genes significantly associated with OS in the TCGA cohort firstly. (Additional file1: Table Figure S1). After filtering the significant genes by LASSO regression (Fig. 2, A, B), we ultimately built a model of 7 genes by multivariate Cox analysis (Additional file3: Table S1). The formula is as follows: ARGM-score = 2028.366416141768 * exp (0.173952736241888 * ANXA1-0.284261956865169 * CASP6-0.438724535364491 * CD2-1.31030529547207 * F2 + 0.238739174665763 * PDGFRb-0.279726650468274 * SATB1-0.17817126370784 * TSPO). The risk score was calculated using the above formula and divided into high and low-risk groups based on their respective median values (Additional file4: Table S2 for TCGA and Additional file5: Table S3 for GSE13507). In Fig. 2, we can see that in terms of overall survival (K-M log-rank test), there are statistical differences between the high-risk group and low-risk group in the TCGA (Fig. 2C, $P < 0.001$). Additionally, the GSE13507 cohorts (Fig. 2D, $P = 0.002$) and the OS of the low-risk group display significantly higher values than that of the high-risk group. The risk profile also indicates that the higher the ARGM-score, the more death cases transpire (Fig. 2E for TCGA; Fig. 2F for GSE13507). Principal component analysis (PCA) reveals the internal structure of data by dimensionality reduction, which helps us better understand data variability [22]. PCA analysis reveals that different risk groups could differentiate bladder cancer patients into two subgroups well after dimension reduction (Fig. 2G for TCGA; Fig. 2H for GSE13507).

2. 列线图

- 这个我们在R语言里学过！

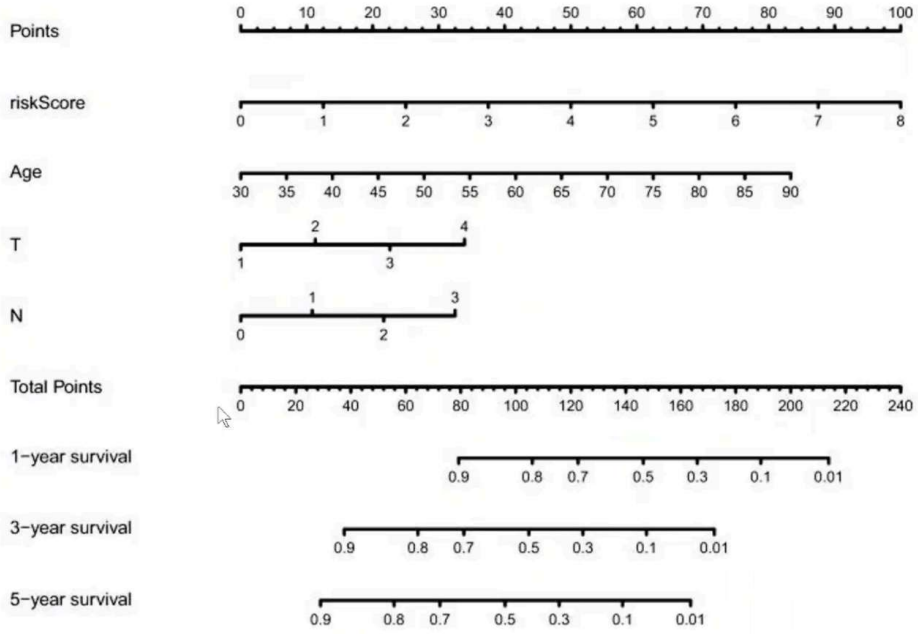

Discov Oncol. 2024;15(1):702.

3. 评分表
   - 是列线图的简化形式，方便临床使用。
   - 不太适合写到论文里，更适合做成果转化。

复发评分 (RS)	风险等级	10年远处复发风险 (仅用内分泌治疗)	化疗获益可能性
< 18	**低风险**	< 10%	极小，不太可能从化疗中获益
18 - 30	**中风险**	约 10% - 25%	有一定获益，需综合其他因素决定
≥ 31	**高风险**	≥ 25%	较大，很可能从化疗中显著获益

4. 风险评分计算器
   - 看起来是自动化+图形界面的列线图

5. 代码
   - 我们这个文件夹就是在Github上备份的！
   - 瑞泽很可能经常用：https://github.com/YouCaiJun98/R_Learning