

2026/4/16

写在前面：这节课还是不用看！看看课件就好！

- 但是这节课讲的东西还挺花里胡哨的，或许看看也不是坏事，反正很快😁

本课课纲

- 本课讲了词云图，词云图是文本可视化的常用手段，如果一个词语在文本中出现的次数比较多，在词云里的尺寸就会更大。



词云图

- 这节课主要用了两个包，`jieba` 和 `wordcloud2`
 - `jieba` 主要用于中文词语分词，这个包在很多编程语言里都有！比如 `python` 里就有！它的底层是 `C++`，把接口打包之后，就可以在其他编程语言中调用了！
 - 什么是“**分词**”？在英文中，词与词之间是空格连接的，所以很好划分；中文中，需要把不同的汉字进行组合，形成有意义的词组，这个过程就叫分词。

- jieba 在 4.5+ 版本的 R 中没有现成的安装包，需要自己本地编译安装（我们之前学过！见系列一！），代码如下：

```
library(devtools)
install_github("qinwf/jiebaRD")
install_github("qinwf/jiebaR")
```

- 介绍了 gsub() 函数，它的作用是全局替换文本里的内容（查找并替换），最常用在数据清洗、删数字、删符号。常见用法如下：

```
gsub(要找的内容, 替换成什么, 在哪里找)
```

举例：

```
# 删除所有数字（把数字替换成空）
tianmao$description <- gsub("[0-9]", "", tianmao$description)
```

上面 [0-9] 表示所有数字，"" 表示空（删掉）。

- 在课程的例子里，讲了一个正则表达式，其中， '\\d' 表示匹配所有数字（0-9）。具体来说， \\d 表示数字（前面的 \\ 表示转义符，记得吗？）在这里，需要双重转义，即写成 '\\d'。
- 介绍了 sort() 函数，它的作用是对向量（数字、字符）进行排序，返回排好序的新向量。基本语法如下：

```
sort(x, decreasing = FALSE, na.last = TRUE)
```

其中，

- x 表示向量（数字、字符串）；
- decreasing=FALSE 表示默认升序（从小到大排序）；反之则是降序，从大到小排序；
- na.last=TRUE 表示 NA 放在最后。
- 使用 wordclou2 包里的 wordcloud2() 函数画词云图！

