04 数据框操作

2026/4/11

写在前面：这节课对数据框的操作比较常规，可以跳过这节课😊

本课课纲

1. 导入外部数据集
2. 生成新变量
3. 变量重命名
4. 提取数据框子集等

导入外部数据集

- 这节课未提供数据集（评论区说置顶链接里有，但是我没有找到），所以我生成了一份，放置在了 `./data` 目录下。
- 本节课处理的表格为 `xlsx` 格式，和之前的 `csv` 格式不同，需要用到 `readxl` 这个包。
- 导入数据集的函数为 `read_excel()` 。
- 在 `R` Studio的数据区也可以导入数据！

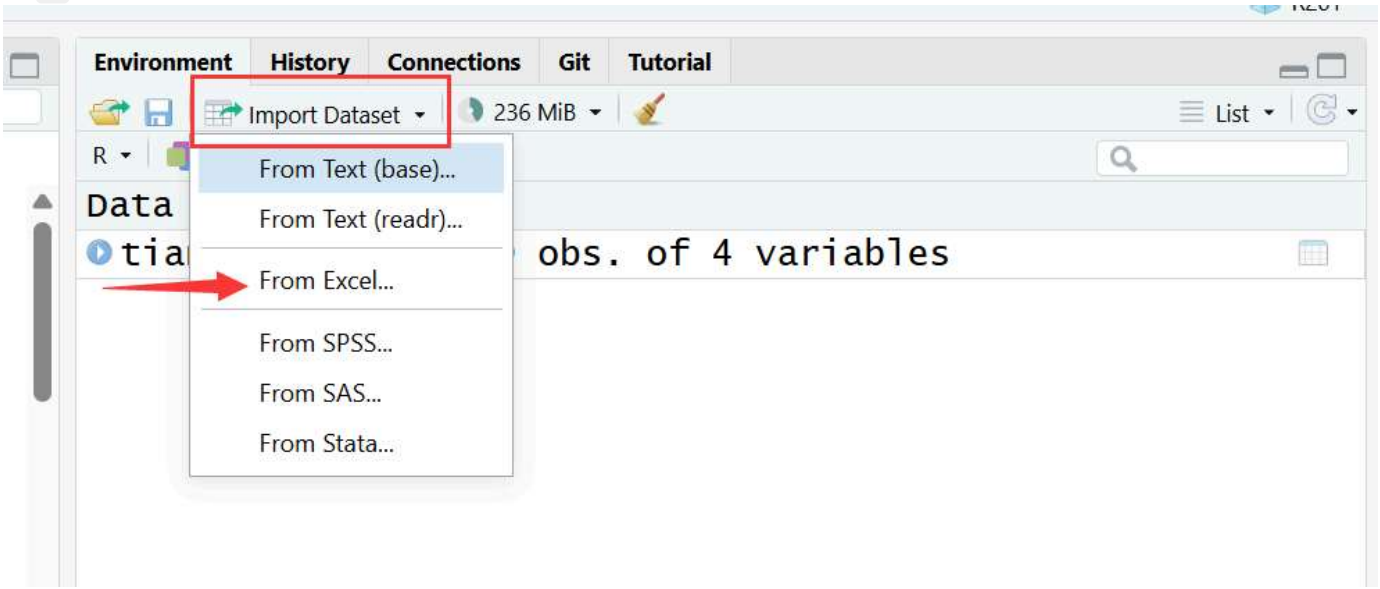

生成新变量

- 取两列向量，进行逐元素相乘，并把结果赋给数据框（取了一个新名字，等于在原数据框中新建了一列）：

```
tianmao['total_sales'] <- tianmao$current_price * tianmao$month_sales_count
# 当然，也可以这么创建：
tianmao$total_sales <- tianmao$current_price * tianmao$month_sales_count
```

- 又用了 `ifelse()` 进行了面向向量的批量化操作。这里用了一个 `ifelse()` 函数的嵌套，实现了双重判断：

```
tianmao['price_tag'] <- ifelse(tianmao$current_price < 1000, 'low price',
                               ifelse(tianmao$current_price <= 2000, 'fair price',
                               'high price'))
```

变量重命名

- 使用 `names()` 函数可以查看数据框的列名。
- 此外，可以直接对 `names()` 的返回结果进行赋值，实现列名的修改，例如

```
names(tianmao)[1] <- 'new_name'
```

- 介绍了一个新的语法， `%in%` ，作用判断一个元素是否存在于另一个集合里，返回 `TRUE` / `FALSE` ，例如

```
元素 %in% 集合
# 例子1
3 %in% 1:5   # TRUE
# 例子2 - 向量批量判断
c(1,6,3) %in% c(1,2,3)  # TRUE FALSE TRUE
```

  - 注意！这个判断运算符非常灵活！ `%in%` 前后的元素可长可短！就课上的例子而言，

```
names(tianmao) %in% "discount"
> [1] FALSE FALSE FALSE FALSE FALSE FALSE FALSE  TRUE FALSE
"discount" %in% names(tianmao)
> [1] TRUE
```

- 讲了一个比较复杂的重命名逻辑，通过 `names(tianmao) %in% "discount"` 语句，以逻辑向量的形式，获取想要重命名的那一列（ `discount` ）的位置，并用这个逻辑向量进行索引，将索引到的列名修改成新名称：

```
names(tianmao)[names(tianmao) %in% "discount"] = 'zhekou'
```

提取数据框子集

- 可以用名称、整数来索引数据框以获取数据框子集，也可以用负索引来剔除部分列，以获取数据框子集。
- 提到了一个小知识点，`!`是布尔值取反操作
- 讲了一个比较复杂的删除部分列的逻辑，通过`ol1_idx <- names(tianmao) %in% col1`以逻辑向量的形式获取想删除的列的索引，取反后提取子集。

```
col1 <- c('new_name', 'shop_name', 'original_price')
col1_idx <- names(tianmao) %in% col1
new_data2 <- tianmao[, !col1_idx]
```

- 提到了一个提取子集的函数，`subset()`。这个函数是常用的数据框 / 向量子集提取函数，作用**按条件筛选行**、**按列名提取列**，基本语法如下：

```
subset(x, subset, select, drop = FALSE, ...)
```

  参数的含义如下：
  - `x`： 待操作的对象（通常是数据框 data.frame，也支持向量、矩阵）；
  - `subset`：**行筛选条件**，逻辑表达式，满足条件的行被保留；
  - `select`：**列筛选条件**，指定要保留 / 删除的列，支持列名、向量、`-`符号；
  - `drop`：仅矩阵 / 数组使用，是否降维，默认`FALSE`。