

MosaicData

2026/4/27

写在前面：这是项目实战系列的第一节课，我们使用 `mosaicData` 包里的 `Births` 数据集，完成数据理解与初始探索、时间序列可视化、周期性分析（weekday effect）、特征构造与分组分析等内容。希望你可以通过这些步骤建立起对数据理解与数据分析的感觉。😊

Step 0 数据集介绍与导入

- 数据集介绍：`Births` 是 `mosaicData` 包中最经典的教学数据集之一，也是统计学入门课程中分析时间趋势、日期效应的常用示例数据。它来自于美国 CDC 公开数据（由 FiveThirtyEight 整理），记录了 1969-01-01 ~ 1988-12-31 全美每日出生数据。数据集中包括 7305 条观测（覆盖 10 年所有日期），常用来做时间序列分析、日期效应、可视化、假设检验的教学。
- 数据导入：

```
install.packages("mosaicData")  
library(mosaicData)
```

- 在数据导入之后，我们可以使用 `head()` 函数检查我们要用的 `Births` 数据：

```
head(Births)
```

Step 1 数据理解与初步探索

- 在我们拿到一个数据集（数据框）之后，可以先浏览一下这个数据框，对数据框的构成产生一个基本的认识：
 - 这个数据框都有哪些变量？这些变量都描述了什么信息？
 - 数据框的变量是什么数值类型？它们的范围是怎样的？如果是分类变量，它们有哪些可能的取值？
 - 数据框里有无缺失数据？我们需要对缺失数据进行怎样的处理（直接删减，还是填充等）？
- 使用常用的数据检查方法来检查这个数据框：
 - `head()` 函数

Description: df [6 x 8]

	date <date>	births <int>	wday <ord>	year <int>	month <int>	day_of_year <int>	day_of_month <int>	day_of_week <int>
1	1969-01-01	8486	Wed	1969	1	1	1	3
2	1969-01-02	9002	Thu	1969	1	2	2	4
3	1969-01-03	9542	Fri	1969	1	3	3	5
4	1969-01-04	8960	Sat	1969	1	4	4	6
5	1969-01-05	8390	Sun	1969	1	5	5	7
6	1969-01-06	9560	Mon	1969	1	6	6	1

6 rows

o glimpse() 函数

```

Rows: 7,305
Columns: 8
$ date      <date> 1969-01-01, 1969-01-02, 1969-01-03, 1969-01-04, 1969-01-05, 1969-01-06, 1969-01-07, ...
$ births    <int> 8486, 9002, 9542, 8960, 8390, 9560, 9738, 9734, 9434, 10042, 9178, 8450, 9834, 10042, ...
$ wday      <ord> wed, Thu, Fri, Sat, Sun, Mon, Tue, wed, Thu, Fri, Sat, Sun, Mon, Tue, wed, Thu, ...
$ year      <int> 1969, 1969, 1969, 1969, 1969, 1969, 1969, 1969, 1969, 1969, 1969, 1969, 1969, 1969, ...
$ month     <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, ...
$ day_of_year <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, ...
$ day_of_month <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, ...
$ day_of_week <int> 3, 4, 5, 6, 7, 1, 2, 3, 4, 5, 6, 7, 1, 2, 3, 4, 5, 6, 7, 1, 2, 3, 4, 5, 6, 7, 1, 2, 3, 4, 5, 6, 7, 1, ...

```

- 可以很清楚地看出来，这个数据是**时间序列数据**（同一个体 / 单位，不同时间点的观测），而不是**横截面数据**（同一时间点，不同个体 / 单位的观测）。
- 随后，进行基础的统计，建立数据直觉：
 - 例如，统计 `births` 变量基本信息（均值、最大最小值、中值等）

```
summary(Births$births)
```

```


      Min.   1st Qu.   Median     Mean   3rd Qu.     Max.
 6675      8792      9622     9649    10510    12851

```


- 下一步，我们要进一步探究，这个数据**是不是有规律可循的**！

Step 2 时间序列可视化

- 因为 `Births` 数据是一个时间序列数据，我们可以用折线图的形式画出来它的变化趋势：



- 我们可以取一个区间做数据切片，看看这个小区间上数据变化的情况：



- 思考：这个数据表现出了怎样的变化趋势？


Step 3 周期性分析

- 从数据切片来看，出生人数的变化**具有一定的周期性**，而且很可能和星期几有关！

- 构造一个新的变量（这一步在这个数据集中是不需要的，因为本来就有"day_of_week"这个一列，不失一般性，我们还是重新构造一个），用来描述星期几，然后检查数据和星期几之间的关系。按照星期几进行分组统计：

weekday <chr>	mean_births <dbl>
星期一	9944.195
星期三	10089.450
星期二	10367.976
星期五	10146.772
星期六	8708.337
星期四	9995.025
星期日	8290.497


- 能看出来，周末的出生人数要显著地比工作日少！
- 我们进一步可视化分组统计的结果：




- 观察柱状图，发现**周末的出生人数要显著地比工作日少！**
 - 出生人数不是随机发生的，它受“星期”这个因素影响！
 - 数据中隐藏着**结构**，我们通过分组把它“挖出来了”！
 - 可能的解释：医院的安排，比如剖腹产、诱导分娩，更可能安排在工作日。

Step 4 特征构造与分组分析


- 我们从上面的步骤里能学到什么呢？
 - 从发现一个规律（weekday）到**系统地构造特征、做分组、做对比！**
- 我们接下来可以做什么？
 - 从日期中构造更多有用特征！
 - 用分组分析做系统性对比；
 - 形成一套可复用的分析流程！
- 一个很自然的问题是，除了weekday以外，出生人数还和哪些时间要素相关呢？
 - 是否和月份相关？
 - 是否和年份相关？
- 我们来构造更多的特征！
 - 按月份分组



- 看起来7/8/9月的出生人数会稍多一些！
- 按年份分组



- 出生人数随着年份也有一定的变化规律！
- 当然，我们也可以找**多个变量**之间的关系，比如 年份 + 月份：



- 我们可以进一步对现象进行发散：
 - 那这些差异意味着什么？比如月份差异，可能和季节、气候、甚至文化因素有关。
 - 需要注意：我们现在看到的是“现象”，不是因果关系！
 - 对于现象的解释，我们可以求助AI。AI可以帮我们提出可能的解释，但这些解释需要我们用数据去验证。
- 总结：时间序列数据 **分析 = 构造变量（分组） + 分组统计 + 可视化！**

Step 5 课程总结

- 对于**时间序列数据**，我们这节课展示了一个非常经典的分析套路：
 - 第一步，通常先看整体情况，建立一个全局印象（基础统计 + 画图）；
 - 第二步，尝试找到结构，比如不同类别之间的差异。这里可能需要我们自己构造变量（构造特征），来实现**数据分组**；
 - 第三步，对分组后的数据进行统计，并用可视化方法辅助，来找到数据和特征之间的关系。
- 但是，我们这节课使用的数据很干净，而且变量很少。真实数据通常会更复杂，比如它会有很多变量、有缺失值、有不同类型的数据。我们在接下来的课程里会对真实世界里的数据进行画图与分析！