

Proj 02 Timely and Effective Care by US States

2026/4/28

写在前面：这节课是我们项目实战的第二节课，我们使用了 tidyuesday 这个[github项目](#)中的开源数据。这节课中，我们将对更复杂、更接近真实的数据进行分析，希望你可以学会一套标准的 EDA（探索性数据分析）流程。😎

Step 0 TidyTuesday与本课数据介绍

TidyTuesday

- [TidyTuesday](#) (#TidyTuesday) 是由 Data Science Learning Community (DSLC, 原 R4DS 社区) 组织的全球性、每周一次的数据实践社区活动，核心是用真实数据集练手数据清洗、可视化与分析，主打 R 语言 tidyverse 生态，也支持 Python / Julia 等编程语言。
- TidyTuesday 的设立初衷是降低数据分析入门门槛，帮助初学者通过真实数据反复练习数据的**获取 — 清洗 — 整理 — 可视化**全流程。
- TidyTuesday 的核心规则是，每周二在 GitHub 发布 1 个真实、开源、干净度适中的数据集合 (CSV/Excel)，附数据字典、来源与背景说明。数据主题广泛，包含社会、经济、体育、环境、历史、娱乐等，多来自公开政府 / 媒体 / 研究数据。
- TidyTuesday 鼓励自由探索与可视化，参与者可使用 R (tidyverse : dplyr / ggplot2 / tidyr)、Python、Julia 等工具做清洗、分析、可视化、建模、报告或 Shiny 应用。无标准答案，鼓励创意表达、技术练习、审美提升，重在过程而非结论。

本课数据介绍

- 本课数据是 TidyTuesday 2025 年第 14 周 (2025-04-08) 的官方数据集：[Timely and Effective Care by US State](#) (美国各州及时有效医疗服务数据)，源自美国 CMS (医疗保险和医疗补助服务中心)，聚焦全美各州医院的急诊等待、诊疗效率、质量指标，非常适合做医疗可视化、州际对比、时间趋势分析。
- 本课数据收录在 care_state.csv 文件中，它的数据规模是 1232 行 × 8 列，数据主题是美国各州按病种 / 指标的医疗服务及时性与有效性评分，可以用来分析急诊等待时长、州间差异、病种效率对比等。
 - 数据覆盖 6 大类疾病 / 服务：急诊、心脏病、肺炎、手术、卒中、预防保健等；

- 数据包含 21 项质量 / 时效指标：如急诊等待时间、给药及时率、救治达标率；
- 可用来探索以下问题：哪些州急诊等待最长 / 最短？哪些病种 / 指标耗时最久？州人口与等待时间是否相关？

Step 1 数据理解与清洗

- 我们之前完成的proj 01数据比较规整、简单，本课中，我们遇到的数据是一个真实的医疗系统数据，它的变量多、结构复杂、而且不干净（存在缺失值等）。
- 首先，我们还是先把数据读进来，并做一个简单的可视化：

```
## 读取数据
library(tidyverse)
care <- read_csv("care.csv")
head(care)
```

A tibble: 6 × 8

state	condition	measure_id
AK	Healthcare Personnel Vaccination	HCP_COVID_19
AK	Healthcare Personnel Vaccination	IMM_3
AK	Emergency Department	OP_18b
AK	Emergency Department	OP_18b_HIGH_MIN
AK	Emergency Department	OP_18b_LOW_MIN
AK	Emergency Department	OP_18b_MEDIUM_MIN

6 rows | 1-3 of 8 columns

能看出来这是一个8列的数据，每列数据的含义可以在 TidyTuesday 上找到：

Data Dictionary

care_state.csv

variable	class	description
state	character	The two-letter code for the state (or territory, etc) where the hospital is located.
condition	character	The condition for which the patient was admitted. Six categories of conditions are included in the data.
measure_id	character	The ID of the thing being measured. Note that there are 22 unique IDs but only 21 unique names.
measure_name	character	The name of the thing being measured. Note that there are 22 unique IDs but only 21 unique names.
score	double	The score of the measure.
footnote	character	Footnotes that apply to this measure: 5 = "Results are not available for this reporting period.", 25 = "State and national averages include Veterans Health Administration (VHA) hospital data.", 26 = "State and national averages include Department of Defense (DoD) hospital data."
start_date	date	The date on which measurement began for this measure.
end_date	date	The date on which measurement ended for this measure.

- 接下来，我们来检查数据中的缺失值：

```
## 检查数据缺失值
library(tidyverse)
colSums(is.na(care))
```

state	condition	measure_id	measure_name	score	footnote	start_date	end_date
0	0	0	0	155	168	0	0

- 简单起见，我们直接剔除数据中的缺失值：


```
## 剔除数据缺失值
library(tidyverse)
care_clean <- care %>%
  filter(!is.na(score))
colSums(is.na(care_clean))
```

```
state      condition measure_id measure_name score footnote start_date
0          0          0          0          0          168          0
end_date
0
```

- 简单总结 Step 1 的工作：首先加载数据，查看数据结构；接下来理解变量的含义（查看变量类型、理解变量的实际含义）；最后处理缺失值（直接剔除NA值）。


Step 2 单变量分析

- 这个数据集中，最重要的因变量是 score，我们对 score 进行可视化：




我们发现 score 的取值范围波动很大！

- 这是因为这个数据中的 score 对应的实际含义可以分为好几个类！例如，对于 Emergency Department，它的 score 指的是在急诊室里等待的时间，这个分数越低越好；对于 Colonoscopy care，它的 score 指的是接受适当随访筛查结肠镜检查建议的患者比例，这个分数越高越好。所在分析时，**需要把不同的情况分开分析！**
- 按照医疗场景分组后，score 的分布与数值范围就更正常一些了：



- 当然，我们也可以和 proj 01 里做过的那样，观察其他自变量的分布。例如，我们可以观察州的分布频数：



- 不同州出现的频数不一样，说明不同州的数据收集存在差异。
- 简单总结 Step 2 的工作：检查自变量/因变量的数据分布，查看是否存在异常。需要特别注意的是，有时需要判断同一变量内的数据含义是否一致 / 是否可比。

Step 3 多变量分析

- 接下来，我们可以考虑分析多个变量之间的关系。对于这个数据集，我们可以提出很多问题，例如：
 - Q1：不同州的医疗表现有没有差异？
 - Q2：同一个州，在不同医疗指标上的表现是否一致？
- 对于Q1，我们需要在同一个 measure（同一个指标）下进行比较
 - 我们首先需要从已有数据中筛选出来我们关心的指标，这里，我们选择评估每个州急诊接待时间，看看它们的分布差异。
 - 我们先过滤原始数据，从中选择 condition 为 Emergency Department 的数据，

```
cond_1 <- "Emergency Department"
```

```
care_ed <- care_clean %>%
  filter(condition == cond_1)
```

我们发现，哪怕在同一个医疗场景（Emergency Department）下，score 对应的物理含义都是不一样的：

state	condition	measure_id	measure_name	score	footnote	start_date	end_date
AK	Emergency Department	OP_18b	Average (median) time patients spent in the emergency department before leaving from the visit A lower number of minutes is better	140	25, 26	2023-04-01	2024-03-31
AK	Emergency Department	OP_18b_HIGH_MIN	Average time patients spent in the emergency department before being sent home A lower number of minutes is better (high)	157	25, 26	2023-04-01	2024-03-31
AK	Emergency Department	OP_18b_LOW_MIN	Average time patients spent in the emergency department before being sent home A lower number of minutes is better (low)	136	25, 26	2023-04-01	2024-03-31
AK	Emergency Department	OP_18b_MEDIUM_MIN	Average time patients spent in the emergency department before being sent home A lower number of minutes is better (moderate)	136	25, 26	2023-04-01	2024-03-31
AK	Emergency Department	OP_18c	Average (median) time patients spent in the emergency department before leaving from the visit- Psychiatric/Mental Health Patients. A lower number of minutes is better	196	25	2023-04-01	2024-03-31
AK	Emergency Department	OP_18c_HIGH_MIN	Average time patients spent in the emergency department before leaving from the visit - Psychiatric/Mental Health Patients. A lower number of minutes is better (high)	230	25	2023-04-01	2024-03-31
AK	Emergency Department	OP_18c_LOW_MIN	Average time patients spent in the emergency department before leaving from the visit - Psychiatric/Mental Health Patients. A lower number of minutes is better (low)	182	25	2023-04-01	2024-03-31
AK	Emergency Department	OP_18c_MEDIUM_MIN	Average time patients spent in the emergency department before leaving from the visit - Psychiatric/Mental Health Patients. A lower number of minutes is better (moderate)	200	25	2023-04-01	2024-03-31
AK	Emergency Department	OP_22	Percentage of patients who left the emergency department before being seen Lower percentages are better	2	25, 26	2023-01-01	2023-12-31
AK	Emergency Department	OP_23	Percentage of patients who came to the emergency department with stroke symptoms who received brain scan results within 45 minutes of arrival Higher percentages are better	60	25	2023-04-01	2024-03-31
AL	Emergency Department	OP_18b	Average (median) time patients spent in the emergency department before leaving from the visit A lower number of minutes is better	145	25, 26	2023-04-01	2024-03-31
AL	Emergency Department	OP_18b_HIGH_MIN	Average time patients spent in the emergency department before being sent home A lower number of minutes is better (high)	172	25, 26	2023-04-01	2024-03-31
AL	Emergency Department	OP_18b_LOW_MIN	Average time patients spent in the emergency department before being sent home A lower number of minutes is better (low)	119	25, 26	2023-04-01	2024-03-31
AL	Emergency Department	OP_18b_MEDIUM_MIN	Average time patients spent in the emergency department before being sent home A lower number of minutes is better (moderate)	168	25, 26	2023-04-01	2024-03-31
AL	Emergency Department	OP_18b_VERY_HIGH_MIN	Average time patients spent in the emergency department before being sent home A lower number of minutes is better (high)	191	25, 26	2023-04-01	2024-03-31

- 所以，我们需要对样例进行进一步限制，确保我们收集的数据的物理含义是一致的：

```
cond_1 <- "Emergency Department"
```

```
cond_2 <- "OP_18"
```

```
care_ed2 <- care_clean %>%
```

```
  filter(condition == cond_1, str_detect(measure_id, cond_2))
```

过滤之后，我们发现，哪怕 measure_id 都限定为了包含 "OP_18"，这些数据的物理含义还是有差异：

state	condition	measure_id	measure_name
6 AK	Emergency Department	OP_18c_HIGH_MIN	Average time patients spent in the emergency department before leaving from the visit - Psychiatric/Mental Health Patients. A lower number of minutes is better (high)
8 AK	Emergency Department	OP_18c_MEDIUM_MIN	Average time patients spent in the emergency department before leaving from the visit - Psychiatric/Mental Health Patients. A lower number of minutes is better (moderate)
5 AK	Emergency Department	OP_18c	Average (median) time patients spent in the emergency department before leaving from the visit - Psychiatric/Mental Health Patients. A lower number of minutes is better
7 AK	Emergency Department	OP_18c_LOW_MIN	Average time patients spent in the emergency department before leaving from the visit - Psychiatric/Mental Health Patients. A lower number of minutes is better (low)
2 AK	Emergency Department	OP_18b_HIGH_MIN	Average time patients spent in the emergency department before being sent home A lower number of minutes is better (high)
1 AK	Emergency Department	OP_18b	Average (median) time patients spent in the emergency department before leaving from the visit A lower number of minutes is better
3 AK	Emergency Department	OP_18b_LOW_MIN	Average time patients spent in the emergency department before being sent home A lower number of minutes is better (low)
4 AK	Emergency Department	OP_18b_MEDIUM_MIN	Average time patients spent in the emergency department before being sent home A lower number of minutes is better (moderate)
18 AL	Emergency Department	OP_18c_VERY_HIGH_MIN	Average time patients spent in the emergency department before leaving from the visit - Psychiatric/Mental Health Patients. A lower number of minutes is better (very high)
17 AL	Emergency Department	OP_18c_MEDIUM_MIN	Average time patients spent in the emergency department before leaving from the visit - Psychiatric/Mental Health Patients. A lower number of minutes is better (moderate)
15 AL	Emergency Department	OP_18c_HIGH_MIN	Average time patients spent in the emergency department before leaving from the visit - Psychiatric/Mental Health Patients. A lower number of minutes is better (high)
14 AL	Emergency Department	OP_18c	Average (median) time patients spent in the emergency department before leaving from the visit - Psychiatric/Mental Health Patients. A lower number of minutes is better

- "OP_18b"指的是急诊科通用患者的离院等待时间（面向所有急诊患者，统计他们从就诊到离开的耗时）
 - "OP_18c"指的是急诊科精神 / 心理健康患者的离院等待时间（专门面向精神 / 心理健康问题的患者）
 - 后缀"_LOW_MIN"指的是低百分位等待时间，代表等待时间较短的患者群体的水平（比如第 25 百分位）
- 所以，我们要把样例的过滤条件设置得更详细一些，我们只看“急诊科通用患者的离院等待时间中位数”：


```
cond_1 <- "Emergency Department"
```

```
cond_2 <- "OP_18c"
```

```
care_ed3 <- care_clean %>%
```


```
  filter(condition == cond_1, measure_id == cond_2)
```

- 最后，我们可视化不同州急诊科通用患者的离院等待时间中位数：




从这张图中，我们可以得出一些结论，比如：

- 在同一个医疗指标下（急诊科通用患者的离院等待时间），不同州之间存在明显差异。
 - 这可能是由于各州的医疗资源、人口密度、医院负荷不同导致的。
 - 但是，这个结论只能说“**相关**”，不能说“**因果**”，因为单纯靠数据分析只能得到相关性的结果，不能把它当成因果性的证据！
- 对于Q2，我们可以在同一个 state（同一个州）下比较不同的 measure 。
 - 我们还是以急诊为例，查看同一个州的不同 measure：



- 可以看出，在同一个系列的指标（OP_18c / OP_18b）下，指标排布的顺序是可以解释的（按照百分位的不同，对应不同的接诊时长）
 - 但是，不同的指标在这张图里没有可比性！比如，OP_23的实际含义是“因卒中症状前往急诊科的患者中，在到达后 45 分钟内获得脑部扫描结果的患者百分比”，它和急诊患者接待时间 / 离院时间放在一起就完全没有可比性！（我们在这里只是展示一下可能的分析口径，这张图在这个场景下确实是没什么太大意义的！）
- 我们可以对上面的图进行修改，将两个州的不同 measure 进行对比：



- 可以看出，在急诊科中，AK州的指标都要比AL州的指标稍好一些，这或许能反映出两个州医疗条件的差异！
- 简单总结 Step 3 的工作：对数据进行简单筛选，并观察不同变量之间的相关关系（设置不同的自变量，观察因变量的变化情况）。在这里，我们还是要注意对齐数据的含义，避免出现不可比的情况！


Step 4 将分析组织成故事

- 在这一节，我们把之前碎片化的观察给组织起来，拼凑出来一个完整的结论。
- 与之前的步骤2、步骤3不同的是，刚才我们是根据数据找解释、下结论，这一节中，我们是带着结论找支撑。我们提出的主问题是，“美国不同州的急诊系统表现是否存在明显差异？”
- 第一步，我们要先定义什么叫“急诊系统表现”。我们限定 condition 为 Emergency Department，限定 measure 为急诊等待时间（这一步和 Step 3 中的 Q1 对应）：


```
cond_1 <- "Emergency Department"
cond_2 <- "OP_18c"

care_ed <- care_clean %>%
  filter(condition == cond_1, measure_id == cond_2)
```


- 第二步，我们先看整体分布。我们暂时先不关心哪个州最好，哪个州最差。我们先聚焦于整体上，急诊等待时间大概是什么水平。我们可以检查急诊等待时间集中在哪个区间、有没有极端值。通过这一步，我们对筛选后的数据**建立起背景认识**：



- 。可以看出，数据主要分布在 200-300 这个区间，此外，还有 >400、>500 的离群数据。
- 第三步，进入核心比较，也就是故事的主体。我们按州比较急诊等待时间的差异（沿用Step 3的图）：



- 可以看出来，有的州（比如PR）急诊等待时间明显高，有的州（比如SD）急诊等待时间非常短，差距可能有数倍。我们可以初步得到结论：**不同州之间，急诊等待时间差异非常明显。**
- 第四步，我们对差异的来源进行解释。和 Step 3 一致，我们可以按照人口密度、医疗资源、医院负荷、城市化程度等角度进行解释。
 - 同样，需要注意，我们现在只能提出可能解释，**不能证明因果关系！**
- 第五步，我们对图进行一些微调，让它服务于我们的结论：



- 当然，我们也可以让AI帮忙解释这一现象。

请根据这张图，总结美国不同州急诊等待时间的特点。你可以按照人口密度、医疗资源、医院负荷、城市化程度等角度进行分析解释。

从这张美国各州急诊科等待时间的条形图，我们可以清晰看到州际差异极大，整体呈现“两头分化”的特征。

一、整体数据特征

- 等待时间跨度极大：从 SD（南达科他州）的~140 分钟，到 PR（波多黎各）的近 500 分钟，相差超过 3 倍。
- “高等待”州集中分布：东北部（MD、DC、DE）、部分西部州（CA、AZ）等待时间明显更长；而中西部、部分山区州（SD、ND、NE、KS）等待时间普遍更短。

二、多维度原因分析

i. 人口密度与城市化程度

- 高密度 / 高城市化州等待时间普遍更长
像 DC（华盛顿特区）、MD（马里兰州）、CA（加州）、NY（纽约州）这些城市化水平高、人口密度大的地区，急诊科面临的患者基数更大、就诊高峰更集中，排队等待的压力自然更高。
- 低密度 / 低城市化州等待时间更短
中西部平原州（SD、ND、NE）人口分散，急诊患者流量低，医院的接诊压力小，因此等待时间普遍更短。

ii. 医疗资源分布与供给

- 资源紧张地区等待时间更长
人口密集的大城市（如 DC、巴尔的摩所在的 MD 州），医疗资源的增长跟不上人口和患

者需求的增长，急诊科床位、医护人员长期处于饱和状态，直接推高了等待时间。

- 资源相对充足地区等待时间更短

部分人口少的州，人均医疗资源（急诊医生、床位）反而更充足，例如 SD、IA（爱荷华州），急诊接诊效率更高，等待时间更短。

iii. 医院负荷与运营压力

- 高负荷州：长期处于“超饱和”状态

像波多黎各（PR）、DC、MD 这些地区，急诊科室长期处于高负荷运转，患者排队、检查、诊疗流程的每个环节都容易出现延误，最终体现在整体等待时间上。

- 低负荷州：运营压力小，流程更顺畅

人口较少的州，急诊科室的患者流量相对平稳，很少出现“挤兑”情况，流程延误少，等待时间自然更短。

三、补充视角：数据解读的注意点

- 这张图展示的是中位数等待时间（对应 OP_18b 指标），但它无法反映“极端长等待”的情况（比如 OP_18b_HIGH_MIN 代表的高百分位等待时间）。
- 像 PR、DC 这类等待时间特别长的地区，很可能同时存在医疗资源不足 + 患者流量集中 + 运营效率低的多重问题。

总结

美国各州急诊等待时间的差异，本质上是人口密度、医疗资源供给、城市化水平和医院运营负荷共同作用的结果：

- 人口密度高、城市化程度高、资源紧张的州（如 DC、MD、CA）→ 等待时间显著更长
- 人口密度低、医疗资源相对充足、医院负荷低的中西部州（如 SD、ND、NE）→ 等待时间普遍更短

- 简单总结 Step 4 的工作：梳理了数据分析工作的思路，① 提出问题 -> ② 限制比较范围 -> ③ 建立证据 -> ④ 给出解释 -> ⑤ 形成结论

Step 5 本课总结

- 本节课展示了**描述性数据分析的基本流程**：① 看数据（结构） -> ② 清洗数据（NA / 类型） -> ③ 看分布（单变量） -> ④ 找关系（多变量） -> ⑤ 画图表达 -> ⑥ 写结论 + 给解释。
- 在这节课里，我们已经学会了如何处理复杂数据、如何判断可比性、如何完成一次 EDA 分析，但到目前为止，我们做的分析仍然是**描述性分析**。在下一个项目里，我们将开始预测（建模）数据！