

Proj 03 Patient Risk Profiles

2026/5/14

写在前面：

这节课是我们项目实战的第三节课，我们还是使用 tidyuesday 这个[github项目](#)中的开源数据。

在前面的项目中，我们从学习 R 语法逐渐过渡到数据分析。在 Proj 02 中，我们开始面对更真实、更复杂的数据，并学习了如何完成一次相对完整的 EDA（探索性数据分析）流程。

本项目更进一步，将从之前简单的数据描述推进到风险分析。在这个项目中，我们将使用 tidyuesday 的 Risk Profiles 数据集，进行风险分析与统计建模训练。我们会学习如何识别 risk factor、如何理解多个变量之间的关系，以及为什么真实研究中需要使用 logistic regression 来分析风险。

整个项目的主线是“**EDA→风险分析→Logistic Regression→模型解释**”，希望你能够建立 statistical modeling 思维，而不仅仅是学会调用模型函数。😊

Step 0 本项目数据介绍

- 本项目使用的数据是TidyTuesday 2023 年第 43 周（发布时间 2023-10-24）的[主题数据集](#)，核心围绕患者风险画像（Patient Risk Profiles）展开，由 Jenna Reps 为庆祝 R/Pharma 大会专门整理发布，是医疗数据分析、风险建模的练习数据集。
- 数据来源是基于真实世界大型医疗数据集训练的逻辑回归模型，**生成了** 100 条模拟患者的完整数据。数据还原了临床场景中“**患者病史特征 + 疾病风险预测**”的典型数据形态，适合用于数据清洗、特征工程、风险建模。数据集未做列名标准化清洗，需要我们自己做字段处理、数据规整。
- 数据集的结构为 100 行 × 100 列，100行对应了 100 位独立模拟患者，100 列分为三大类核心字段，患者唯一标识字段（1 列）、患者特征字段（85 列，二分类 0/1 变量）、疾病风险预测字段（14 列，0-1 连续数值）。字段的详细说明如下：
 - 患者唯一标识，1个，整数，每位模拟患者的唯一 ID，无重复值
 - 患者特征字段，85 个二分类字段，1 代表患者符合该特征 / 有该病史 / 有该用药史，0 代表不符合 / 无，具体分为以下子类：
 - 年龄分组特征 20 个，覆盖全年龄段的 5 岁间隔分组，包括
age group: 0 - 4 、...、 age group: 90 - 94 ；
 - 性别特征，2 个， Sex = FEMALE & Sex = MALE 分别表示患者为女 / 男；
 - 既往病史与疾病特征，40 个，覆盖了循环系统、呼吸系统、消化系统、内分泌系统、神经系统、精神类疾病等全科室常见疾病；
 - 用药与治疗史特征，18 个，覆盖了常见处方药、抗生素、激素类药物的暴露史；
 - 生活习惯与其他特征，5 个，包括吸烟史、饮酒史等健康相关行为特征。
 - 疾病风险预测字段，14 个，所有风险字段均为 0-1 之间的连续数值，代表基于患者当前特征，模型预测的未来 1 年发生该结局的概率，0=0% 概率，1=100% 概率。

Step 1 数据理解与变量探索

数据理解

- 之前我们已经尝试了做基础 EDA、看变量分布、做简单多变量分析，这些都是在描述数据长什么样，我们关心的是数据怎么分布、指标有什么特征。在这个项目中，我们将接触患者风险数据，更关心的是哪些变量是真正重要的（是潜在的风险因素）、哪些变量只是伴随出现、哪些变量可能彼此相关，以及如何从数据中提出风险假设。
- 接下来，还是按照之前的数据理解流程，读入数据、理解数据、清洗数据。
 - （这里我们就直接看工作区里的变量了）

age group: 80 - 84	age group: 90 - 94	Sex = FEMALE	Sex = MALE	Acetaminophen exposures in prior year	Occurrence of Alcoholism in prior year	Anemia in prior year	Angina events in prior year
0	0	1	0	1	0	0	0
0	1	0	1	0	0	0	0
0	0	0	1	0	0	0	0
1	0	0	1	0	0	0	0
0	0	1	1	0	0	1	0
0	0	0	1	0	0	0	0
0	0	1	0	0	0	1	0
0	0	1	0	0	0	0	0
0	0	1	0	0	0	0	0
0	0	1	0	0	0	0	0

- 在拿到数据时，需要考虑一个变量是连续变量还是分类变量、它的数值类型是什么、它可能是 risk factor 还是 outcome，它的实际意义是什么、可能和哪些变量相关等。
- 因为这个数据集是逻辑回归模型生成的数据集，所以没有缺失值。
- 如 Step 0 所示，我们可以对这100列变量进行分组，除了第 1 列的序号外，大致可以分成三类：
 - 第一组是人口学变量，例如 age group: 65 - 69、Sex = FEMALE，这些变量的特点是 0/1 编码。某个年龄组为 1，表示这个人属于该年龄组；Sex = FEMALE 为 1，表示这个人是女性。
 - 第二组是既往一年中的健康状态、疾病、用药或暴露，例如 Hypertension in prior year，这些变量也是 0/1 编码，它们不是连续指标，而是是否发生过/是否存在过的标记。
 - 第三组是预测风险变量，例如 predicted risk of Pulmonary Embolism，这些数据不是实际发生的疾病结局（原始临床 outcome），而是由某种模型给出的预测风险。我们在后续做 logistic regression 之前，需要明确后续如何构造 outcome，而不是直接把它当成真实疾病发生结果（比如，我们可以用一个阈值来截取数据）。

数据检查

- 检查 0/1 类型的指示变量
 - 我们可以挑几个 0/1 取值的指示变量来观察：

A tibble: 2 × 2

	Sex = FEMALE <dbl>	n <int>
0		57
1		43

2 rows

- 这里的“0” / “1”就是一个分类变量，表示是否符合某个条件。它的和自然是100（样本总量）。
- 检查人口学变量是否合理
 - 理论上这个项目中的人口学变量应该是 one-hot 编码：一个人应该只属于一个年龄组、性别组

A tibble: 1 × 2

n_age_group	n
<dbl>	<int>
1	100

1 row

- 这里我们对每个样本都按年龄 / 性别求和，求和的结果是 `n_age_group`，因为一个人应该只属于一个年龄组、性别组，所以它的结果是1。（反之，如果不是1，那么一个人就对应了多个年龄 / 多个性别，那数据就出错了！）

- 探索既往疾病与用药特征

- 我们可以挑选一些 `prior year` 变量，查看这些特征在样本中的出现比例：

A tibble: 1 × 4

hypertension_rate	obesity_rate	smoking_rate	diabetes_rate
<dbl>	<dbl>	<dbl>	<dbl>
0.16	0.17	0.13	0.11

1 row

- 可以发现，0/1 编码的变量不仅可以用 `count()` 计数，也可以用 `mean()` 来计算它在样本中的比例。

- 探索预测风险（predicted risk）变量

- 接下来可以观察几个 `predicted risk` 的分布（注意，我们可以把这些 `predicted risk` 改造成 `outcome`!）

A tibble: 1 × 3

mean_pe	mean_dementia	mean_migraine
<dbl>	<dbl>	<dbl>
0.003913707	0.02854544	0.008307453

1 row

- 这些风险值通常会很小，而且分布可能很偏。这在医学风险预测中很常见，因为很多疾病事件本身就是低发生率事件。但是，即使 0.02 这样的预测风险，也可能已经代表相对较高的风险。

本节小结

- 这一小节我们检查了数据，这份数据由人口学 one-hot 变量、prior year 的疾病/用药/暴露指示变量，以及多个 `predicted risk` 变量共同组成。我们先建立对数据结构的正确理解，弄清楚哪些变量是特征、哪些变量是预测风险、哪些变量可以被构造成 `outcome`，后面才可以做多变量 EDA、风险画像和 logistic regression。


Step 2 多变量 EDA 与风险画像

- 本项目中的变量大多数是 0/1 指示变量，每一列代表某种人口学特征、既往疾病、用药或暴露，每个样本还对应了多个预测风险值。我们在分析时，已经不能一个指标一个指标地看数据了，这 and 实际情况也是对应的：现实中的患者特征往往是组合出现的。例如，某个患者可能同时属于高年龄组、有高血压、有糖尿病、有心衰、使用过某些药物。这要求我们不能只看单个变量，而是需要考虑**变量之间的协同关系** / 多个变量同时作用下的风险画像。
- 我们可以提出许多问题，例如：
 - 多个风险变量之间是否存在关联？
 - 哪些疾病经常共同出现？
 - 不同年龄组的风险模式是否不同？

- 哪些特征与高 predicted risk 相关？

特征组合

- 我们可以选择若干风险变量，观察它们之间的关联。我们通过计算两两变量之间的相关性来描述它们的关联程度：



- 可以通过热力图的形式展示不同变量之间的关联程度，它反映了这些特征是否倾向共同出现。

疾病共现

- 除了风险因素可能彼此相关外，疾病也可能关联出现，这应该也是比较符合现实中医学分析的，我们关心的可能不仅仅是单个疾病，而是共病（comorbidity）。我们可以很自然地提出问题，比如：
 - 高血压与糖尿病是否经常同时存在？
 - 某些疾病组合是否特别常见？
- 以高血压和二型糖尿病为例，我们观察它们的频次：

Hypertension in prior year	Type 2 Diabetes Mellitus (DM), with no type 1 or secondary DM in prior year	n
<dbl>	<dbl>	<int>
0	0	76
0	1	8
1	0	13
1	1	3

- 在所有的 24 个病例中，同时患有高血压（对应 Hypertension in prior year 取值为1）和二型糖尿病（对应 Type 2 Diabetes Mellitus (DM), with no type 1 or secondary DM in prior year 取值为1）的病人有3位，看起来是一个比较高的比例了。

年龄组与风险模式

- 某些疾病的发生应该和年龄有很大的关系，我们还可以探究不同年龄组的疾病发生风险模式，也就是**风险分层**。
 - 我们以痴呆症为例，它在人群中发生的均值（注意，我们在这里只是简单地在这 100 个样本中，对发生风险取了平均值）是：

```

dementia_risk
<dbl>
0.02854544
1 row

```

- 我们把样本按照年龄分组，再检查不同年龄组人群发生痴呆症的风险：

A tibble: 19 × 2


age_group	mean_dementia_risk
age group: 50 - 54	2.450167e-03
age group: 55 - 59	7.310305e-03
age group: 60 - 64	9.072062e-03
age group: 65 - 69	1.183411e-02
age group: 70 - 74	1.290899e-02
age group: 75 - 79	8.137794e-02
age group: 80 - 84	1.221090e-01
age group: 85 - 89	9.167795e-02
age group: 90 - 94	2.860649e-01

11-19 of 19 rows

可以看出，痴呆症发生的风险和年龄增长还是有比较明显的正相关性的。


哪些特征与 predicted risk 更相关（单因素风险探索）

- 我们已经探索了风险因素之间的关联、疾病之间的关联、年龄组和疾病风险的关联，下一步，我们可以把“年龄组”进行推广，探索风险因素和疾病风险之间的关联。
 - 例如，我们可以探索，有高血压史的病人，他们发生肺栓塞的可能性会不会更高？



可以看出，有高血压史的病人，他们发生肺栓塞风险的概率中位数要更高一点，但总体很难看出有多大的关联性。

- 我们可以多看几组风险因素和疾病风险概率的关系，画出小提琴图：



看起来，我们这次挑选的因素和肺栓塞的关联都比较明显。

- 当然，因为这组数据中没有真实的医疗结果（outcome），所以我们分析的都是特征与预测风险的关系。

单变量分析的局限

经过上述的单因素风险探索，我们发现一项疾病可能与许多风险因素关联，也就是风险变量是混杂（confounding）的。当多个变量彼此相关时，简单比较可能误导。所以，我们需要考虑这些因素之间的混杂效应，也就是为什么我们需要logistic regression。

本节小结

- 在这一小节中，我们第一次开始分析“风险画像”。相比上一小节中对单个变量的理解，我们这一小节更关心的是不同特征之间如何共同出现，不同患者群体的 predicted risk 是否存在差异，以及多个 prior year 特征是否可能共同影响风险。
- 在这个过程中，我们开始接触一些概念，比如共病（comorbidity）、风险分层（risk stratification）、特征共现（co-occurrence）和混杂（confounding）。
- 我们意识到，简单的单变量分析已经越来越难回答复杂问题，这就引出了下一小节的问题，“如果多个变量会同时影响 risk，我们能不能用一个 statistical model，统一分析这些变量？”

Step 3 构造 Outcome 与 Logistic Regression 入门

- 在前两个小节中，我们分别进行了 patient risk profiles 数据理解和多因素EDA。我们之前的分析都是一个变量一个变量地看，而现实中的风险往往是多个因素共同作用的。我们想知道，能不能用一个统一的模型同时分析这些变量？这也就是这一小节要引入的Logistic Regression。
- 我们在这一小节要解决的问题有；
 - 什么是 outcome、如何构造binary outcome；
 - logistic regression 在解决什么问题。

什么是outcome & 构造binary outcome

- 这个项目中的疾病风险数据都是 predicted risk of ...，这些变量不是真实疾病是否发生（不是临床结局 outcome），而是某种模型预测出的风险值。为了做Logistic Regression，我们必须自己构造 outcome。
- 我们可以这样构造一个二元结局，将 predicted risk of Pulmonary Embolism 排名前 10% 的样本标记为高风险：

```

threshold <- quantile(
  risk$`predicted risk of Pulmonary Embolism`,
  0.9
)

risk <- risk %>%
  mutate(
    high_pe_risk =
      if_else(
        `predicted risk of Pulmonary Embolism`
          >= threshold,
          1,
          0
      )
  )

```

- 很多医学问题本质上都在回答某件事会不会发生，例如，患者是否属于高风险人群、是否进入风险最高的群体、是否需要进一步干预，这类问题有一个共同特点，即 outcome 只有两种状态，也就是我们这里构造的二元结局（Binary Outcome）。

logistic regression

- logistic regression 在做什么：Logistic Regression 本质上在回答，当给定某些特定条件的时候，某件事发生的概率是多少。也就是说，它是**基于选定的条件，建立某事发生的概率模型**。
- 我们可以建立一个简易的模型：

```

model <- glm(
  high_pe_risk ~
    `Heart failure in prior year`,
  family = "binomial",
  data = risk
)

```

- 再使用 `summary(model)` 来检查这个模型：

```

call:
glm(formula = high_pe_risk ~ `Heart failure in prior year`, family = "binomial",
    data = risk)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)    -2.6532     0.4627  -5.734 9.79e-09 ***
`Heart failure in prior year`  1.3182     0.6832   1.930  0.0537 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 65.017  on 99  degrees of freedom
Residual deviance: 61.440  on 98  degrees of freedom
AIC: 65.44

Number of Fisher Scoring iterations: 5

```

对于这个模型的解释，我们下一小节再做展开！

本节小结

- 之前的探索中，简单的 EDA 虽然能够帮助我们观察数据、发现趋势、提出问题，但当多个变量开始共同影响风险时，仅靠简单比较已经越来越难真正回答问题。
- 在这一小节中，我们开始尝试用一个统一的 statistical model 同时分析多个特征，并预测某个患者是否属于高风险群体。我们构造了二元的结局变量，并引入了 logistic regression。
- 我们会在下一小节中解释 Logistic Regression 的结果 😊

Step 4 单因素 Logistic Regression

- 我们在上一节中第一次建立了一个 statistical model 模型，这一小节中，我们开始解释这个模型，对应了风险解释（risk interpretation）。我们在这一小节中将会解释 Logistic Regression 中的若干变量：
 - coefficient 是什么意思；
 - 什么是 odds；
 - 什么是 odds ratio (OR)；
 - p-value 在回答什么；
 - CI 为什么重要；
 - 为什么统计显著不等于现实重要。

coefficient - 影响的方向

- coefficient 代表了影响的方向：
 - coefficient > 0 表示变量更容易进入高风险组；
 - coefficient < 0 表示风险可能降低。
- 在当前的模型里，Heart failure in prior year 系数为正，看起来与更高风险相关。
- 但是，这个建模结果合理吗？各个变量对结局的影响有多显著？

Odds - 相对可能性

- 回答上述问题以前，我们先介绍 Odds，它表示了一种“相对可能性”，它的实际含义是，事件发生的概率与不发生的概率的比值。
- 例如，100个样本中，80 个属于高风险，20 个属于低风险，那么

$$\text{odds} = 80/20 = 4$$

也就是说，高风险的可能性，是低风险的 4 倍。

Odds Ratio - 变量让 Odds 改变的程度

- Logistic Regression 关心的是某个变量会让 odds 改变多少，例如，OR = 2 表示高风险的 odds 变成原来的 2 倍，而 OR = 0.5 意味着 odds 降低一半。

- 在当前模型中，Heart failure coefficient = 1.31 表示有心衰既往史的人更容易进入我们标定的高风险组。我们可以根据这个建模结果进一步计算 OR 值：

```
exp(coef(model))
```

- 计算结果如下：

```
(Intercept)  `Heart failure in prior year`
0.07042254      3.73684211
```

这意味着，有心衰既往史的人，进入高风险组的 odds 大约是其他人的 3.7 倍。

- 然而，尽管心衰的效应大小（effect size）非常大（OR值接近4），但我们**不能将它描述为统计显著**，这是因为当前模型中，心衰的 Std. Error = 0.683，这意味着模型对这个效应的估计不够稳定。这可能是因为样本量太小、high risk 人群太少、心衰本身较少见、数据波动较大等。

p-value - 证据的强弱程度

- p-value 本质上是在问，如果这个变量实际上没有效果（原假设为真），我们观测到当前这样的系数（或更极端结果）的概率有多大。

它反映了“变量效应是随机噪声导致”的可能性，p值越小，说明“这种效应是偶然出现”的概率越低，我们拒绝“变量无效应”的证据越强；

反之，p值越大，说明当前数据不足以排除“效应只是随机波动”的可能，我们对变量是否真的存在效应的信心不足。

Confidence Interval - 置信区间

- 真实数据永远存在随机性，所以 OR 不可能是一个绝对真值。统计学需要给出一个可能的范围。对于我们建立的模型，计算出来的置信区间为：

```
                2.5 %      97.5 %
(Intercept)      0.02469856  0.1575223
`Heart failure in prior year` 0.95096243 14.7745473
```

- 还是以心衰为例，它的 OR 值是1.318，对应的p值是0.0537，这只是对真实总体 OR 的一个点估计。而 95%CI 区间我们计算出来是0.950~14.774，它的含义是，我们有 95% 的信心认为，真实的总体 OR 值在 0.950 到 14.774 之间。
- CI 通常比单独 p 值更重要，这是因为：
 - p 值只告诉你是否显著，但不告诉你效应有多大（需要搭配 OR 值）、不确定性如何；
 - CI 同时包含效应大小（区间中心）、不确定性（区间宽度，宽度越大越不稳定）。

本节小结

- 在上一小节中，我们发现建模的重要性，而在这一小节里，我们解释了模型中变量的含义。我们探索了coefficient、OR 值（优势比）、p-value等模型系数的含义，结合数据背景与统计不确定性去理解这些结果。
- 在下一小节中，我们将进一步探索，如果多个变量之间彼此相关，模型结果会发生什么变化。

Step 5 多因素 Logistic Regression

- 在上一小节中，我们解释了 Logistic Regression 的结果，并掌握了coefficient等模型描述的概念。我们还开始思考，为什么某些变量效应很大却不显著、为什么某些结果会不符合直觉等。
- 但是，我们只是对结果进行一定解释，并没有区分出变量之间的相互影响：现实中的**变量，往往不是独立存在的**。例如，有心衰的患者，可能也更容易高龄、有高血压、糖尿病等。换句话说，我们看到的效应本身，究竟是这个变量单独的作用，还是与它共同出现的其他特征导致的（即 Confounding）？我们在这一小节中将进一步探索，当多个变量彼此相关时，模型结果会发生什么变化。
- 在这一小节里，我们将会：
 - 进一步解释 confounding 和 adjustment；
 - 引入独立效应（Independent Effect）。

从单因素 Logistic Regression 到多因素 Logistic Regression

- 根据我们之前的分析结果（Heart failure OR ≈ 3.7 ），有心衰既往史的人，进入高风险组的 odds 大约是其他人的 3.7 倍，（这里不考虑样本数量较少、方差较大的问题）看起来是心衰一个非常强的风险因素。但是，这一效应真的只是心衰这个单独的变量产生的吗？还是说，这里其实也部分掺杂了其他影响因素产生的效应？
- 我们可以考虑引入其他的风险因素，比如年龄。年龄几乎影响所有慢病，进而会影响大多数风险模型。如果不控制年龄，年龄的效应会混入其他风险变量的效应里（也就是confounding），所以我们修改我们的单因素 Logistic Regression 模型，把它改造成一个多因素 Logistic Regression 模型：

```
model_multi <- glm(
  high_pe_risk ~
    `Heart failure in prior year` +
    `age group: 80 - 84` +
    `Hypertension in prior year`,
  family = "binomial",
  data = risk
)
```

Confounding 与 Adjustment

- 我们接着查看多因素 Logistic Regression 模型的 OR 值，如下图所示：

(Intercept)	`Heart failure in prior year`	`age group: 80 - 84`	`Hypertension in prior year`
0.07567055	3.50278675	1.90392874	0.50559870

- 可以发现，加入年龄这一风险因素后，心衰的 OR 值从 3.736 降低至 3.502，这说明，之前单因素模型中心衰的效应是混杂的（confounding），它一部分来源于年龄的影响。而加入年龄后，模型开始控制年龄，心衰的影响也被重新估计，也就是Adjustment。
- 需要注意的是，哪怕做了调整（Adjustment），模型依然可能因为有遗漏变量、有 measurement bias、有 hidden confounding而存在偏差！多变量模型能够减少部分 confounding，但无法保证完全消除 bias！

独立风险因素

- 多变量模型想回答的问题是，在其他条件相同（年龄相近、慢病情况相近）的人中，某一因素（如心衰）是否是风险因素。如果我们把其他因素的效应都排除了（把这些因素引入模型），发现心衰的 OR 值还是大于1，就说明它是一个独立风险因素。

模型预测

- 我们在拿到这个多因素模型后，可以用这个模型去预测样本在风险因素的组合下，发生危险的可能。
 - 我们可以预测原始数据上各个样本高风险的可能性：

```
predict(model_multi, type = "response")
```

结果如下所示，每个样本都会对应一个分数（概率）：

```

1      2      3      4      5      6      7      8      9      10     11     12     13     14
0.07034733 0.12592863 0.07034733 0.20952229 0.07034733 0.07034733 0.20952229 0.07034733 0.07034733 0.07034733 0.20952229 0.07034733 0.07034733 0.07034733
15     16     17     18     19     20     21     22     23     24     25     26     27     28
0.03684912 0.03684912 0.07034733 0.07034733 0.03684912 0.20952229 0.07034733 0.07034733 0.07034733 0.07034733 0.07034733 0.07034733 0.07034733 0.07034733
29     30     31     32     33     34     35     36     37     38     39     40     41     42
0.07034733 0.11817580 0.20952229 0.07034733 0.07034733 0.07034733 0.07034733 0.07034733 0.07034733 0.20952229 0.07034733 0.20952229 0.07034733 0.20952229
43     44     45     46     47     48     49     50     51     52     53     54     55     56
0.07034733 0.07034733 0.03684912 0.03684912 0.07034733 0.07034733 0.07034733 0.07034733 0.20952229 0.33539413 0.03684912 0.07034733 0.11817580 0.07034733
57     58     59     60     61     62     63     64     65     66     67     68     69     70
0.07034733 0.20952229 0.20952229 0.07034733 0.07034733 0.07034733 0.20952229 0.07034733 0.07034733 0.20952229 0.20952229 0.07034733 0.07034733 0.07034733
71     72     73     74     75     76     77     78     79     80     81     82     83     84
0.03684912 0.03684912 0.20952229 0.20952229 0.07034733 0.03684912 0.20952229 0.20328310 0.07034733 0.07034733 0.03684912 0.07034733 0.07034733 0.07034733
85     86     87     88     89     90     91     92     93     94     95     96     97     98
0.07034733 0.07034733 0.07034733 0.07034733 0.07034733 0.07034733 0.07034733 0.07034733 0.20952229 0.03684912 0.07034733 0.07034733 0.03684912 0.11817580
99     100
0.07034733 0.33539413

```

- 当然，我们也可以构造一个新的样本出来，用模型来预测这个新样本高风险的概率：

```

new_patient <- data.frame(
  check.names = FALSE,
  `Heart failure in prior year` = 1,
  `age group: 80 - 84` = 1,
  `Hypertension in prior year` = 0
)

predict(model_multi, newdata = new_patient, type = "response")

```

预测结果如下所示：

```

predict(model_multi, newdata = new_patient, type = "response")
...
1
0.3353941

```

本节小结

- 我们在这一小节中遇到了多个变量对模型结果的影响。我们发现，单因素 OR 与多因素 OR 会不同，进一步了解了 confounding 和 adjustment，并接触了 Independent Effect。应该意识到，模型中的效应往往不是某个变量天然的影响，而是在控制其他变量后，重新估计得到的。

Step 6 模型局限性

- 到目前为止，我们已经建立 Logistic Regression 并做了单因素与多因素分析。但是，我们经常会遇到模型结果不合理的问题。例如，为什么 adjustment 后 OR 没有明显变化？为什么某些变量看起来 effect 很大，但不显著？这是因为，我们建立的模型只是对现实的一种近似描述。在这一小节中，我们要去正确理解模型。

模型结果异常（稀疏数据）

- 我们把上一小节中的多因素模型进行简单修改，把年龄分组换成 85-89 岁：

```
model_multi <- glm(
  high_pe_risk ~
    `Heart failure in prior year` +
    `age group: 85 - 89` +
    `Hypertension in prior year`,
  family = "binomial",
  data = risk
)
```

我们发现，这个模型直接炸了，它的 OR 值出现了一个极低的小值：

```
(Intercept) `Heart failure in prior year` `age group: 85 - 89` `Hypertension in prior year`
8.030981e-02 3.825374e+00 1.833684e-07 5.022758e-01
```

- 这可能是因为**数据太稀疏**。这个项目中样本的总量是100，同时符合高风险组+年龄组的样本可能非常少。这时，模型会尝试极端地分离这部分样本，这就会导致 coefficient 非常极端，OR 接近 0 或无限大，出现不稳定估计的问题。
- 这个现象在临床分析中应该非常常见，医学数据往往不是大量均匀数据，比如，某些疾病很少见、某些年龄组人数很少、某些风险 outcome 本身就稀少。此时，模型中的很多变量组合几乎没有样本，这时再进行 Logistic Regression 结果就会非常不稳定。

p-value是万能的吗

- 回到我们之前的单因素模型。模型的描述参数为：

```
Call:
glm(formula = high_pe_risk ~ `Heart failure in prior year`, family = "binomial",
    data = risk)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)    -2.6532     0.4627  -5.734 9.79e-09 ***
`Heart failure in prior year`  1.3182     0.6832   1.930  0.0537 .
```

- 我们之前下的结论是，虽然心衰的效应大小（OR值）很大，而且p值很低，但是我们不能将它描述为统计显著，这是因为当前数据样本量不大、outcome 稀少、方差很大。即使 OR 很高，模型仍然可能不够确定。总结起来，**统计显著和效应大小是两件事情**。

真实模型不一定符合直觉

- 我们可以再构造一个多因素模型出来：

```

model <- glm(
  high_pe_risk ~
    `Hypertension in prior year` +
    `Heart failure in prior year` +
    `Type 2 Diabetes Mellitus (DM), with no type 1 or secondary DM in prior year`,
  family = "binomial",
  data = risk
)

```

- 检查它的结果，发现高血压对应的 OR 值小于1，它居然是一个保护因素：

```

Coefficients:
(Intercept)                -2.58428    0.49164   -5.256 1.47e-07 ***
`Hypertension in prior year` -0.64182    1.11993   -0.573  0.5666
`Heart failure in prior year`  1.33281    0.68750    1.939  0.0525 .
`Type 2 Diabetes Mellitus (DM), with no type 1 or secondary DM in prior year` 0.09347    1.14046    0.082  0.9347
---

```

- 这可能是受到了混杂、稀疏数据、当前 outcome 的定义方式等因素的影响。尤其是，当前的 outcome 本来就是从 predicted risk 构造出来的，它不是真实疾病发生。
- 我们可以产生一种认识，即**模型结果本来就不一定符合现实医学常识，它必须结合数据来源理解。**

关联性不等于因果性

- 我们在分析中发现心衰的 OR 值约等于3.7（先不考虑样本数量等其他因素），这也不代表心衰一定导致高风险。这是因为，一方面，我们的数据本身是观测数据，而且结局变量还是基于风险预测的结果派生的。**模型只能说明关联性，不能代表因果性。**

本节小结

- 在这一小节中，我们对建模的局限性进行了分析。应当产生这样一种认知，真实模型的结果往往并不完美，它永远只是对现实的一种近似描述。重要的不是相信模型，而是理解模型为什么会得到这样的结果，以及这些结果可能受到哪些因素影响（数据背景、变量关系、数据质量、样本结构等）。

项目总结

- 在 Proj 03 中，我们进行了一次完整的真实风险分析：从理解风险数据、提出风险问题，到分析多个变量之间的关系，再到建立并解释 logistic regression model。
- 在这一过程中，我们学习了 OR、CI、p-value、confounding、adjustment 等医学统计中的概念。我们应该能产生一种认知，即统计模型并不是自动生成答案的机器，而是一种帮助我们理解现实的工具。
- 我们发现，现实中的风险因素往往不是单独存在的。变量之间会彼此关联，单变量分析也可能受到 confounding 的影响。因此，在做数据分析时，我们需要做的并不仅仅是发现关系，而是不断思考：这个关系是否可靠、是否受到其他变量影响、是否可能被误解。
- 在接下来的 Proj 04 中，我们会继续面对更加复杂、更接近真实公共卫生与流行病学场景的数据，并进一步学习如何把数据分析组织成一个完整、合理、具有解释性的分析故事！🧐