

Proj 04 WHO TB Burden Data

2026/5/16

写在前面：

这个项目是我们项目实战中的最后一个项目，我们还是使用 tidyuesday 这个[github项目](#)中的开源数据。

在前面的几个项目中，我们分析的数据大多围绕个体展开。无论是出生数据、医疗质量数据，还是患者风险画像，我们关注的核心问题通常都是某个变量如何变化、某类患者风险是否更高、哪些因素与结局有关，以及统计模型如何解释风险。

而本项目中，数据中的主体不再是患者，而是国家、地区与人群。我们面对的，不再是个体层面的分析，而是“某个国家为什么承担了更高的疾病负担”等宏观问题，数据分析的思维方式也会随之发生变化。我们会尝试用数据去理解全球疾病负担，分析疾病在时间上的变化趋势，比较不同地区之间的差异，并逐渐学习如何把这些分析组织成一个完整的公共健康故事。 😊

Step 0 本项目数据介绍

- 本项目使用的数据是TidyTuesday 2025 年第 45 周的 [WHO 全球结核病（TB）负担数据](#)，数据来源为世界卫生组织官方发布的全球结核病负担估算结果，是可用于公共卫生领域与数据分析学习的优质结构化数据集。
- 本数据集提供了国家层面的结核病全维度核心指标，覆盖 2000-2023 年的长时序数据，可用于分析全球 / 区域结核病发病率、死亡率的长期变化趋势，对比不同国家 / 地区的结核病防控效果（病例检出率、病死率等），研究 HIV 感染与结核病死亡率的关联特征等。
- 数据集的结构为 5117 行 × 18 列，数据集字段可分为 5 大类，包括：
 - i. 基础标识字段（包括国家 / 地区名称、所属 WHO 区域、观测年份等）
 - ii. 病例检测与防控效果指标（包括病例检出率、每 10 万人病例报告率等）
 - iii. 发病率估算核心指标（包括每 10 万人结核病发病率、结核病发病总人数估算值）
 - iv. 死亡率估算核心指标（每 10 万人结核病总死亡率、结核病死亡总人数估算值等）
 - v. 人口基础指标（对应国家 / 地区当年估算总人口数）

Step 1 数据理解与流行病学指标理解

数据理解

- 继续按照之前的数据 pipeline 进行数据理解。读入数据、理解数据、清理数据：

```
Rows: 5,117
Columns: 18
$ country
$ g_whoregion
$ iso_numeric
$ iso2
$ iso3
$ year
$ c_cdr
$ c_newinc_100k
$ cfr
$ e_inc_100k
$ e_inc_num
$ e_mort_100k
$ e_mort_exc_tbhiv_100k
$ e_mort_exc_tbhiv_num
$ e_mort_num
$ e_mort_tbhiv_100k
$ e_mort_tbhiv_num
$ e_pop_num
<chr> "Afghanistan", "Afghanistan", "Afghanistan", "Afghanistan", "Afghanista...
<chr> "Eastern Mediterranean", "Eastern Mediterranean", "Eastern Mediterranea...
<dbl> 4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 4, 4, ...
<chr> "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF", ...
<chr> "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "
<dbl> 2000, 2001, 2002, 2003, 2004, 2005, 2006, 2007, 2008, 2009, 2010, 2011, ...
<dbl> 19, 26, 34, 32, 41, 47, 53, 59, 56, 50, 52, 50, 51, 51, 56, 64, 69, ...
<dbl> 35, 50, 65, 61, 78, 90, 100, 111, 107, 95, 99, 95, 94, 96, 97, 106, 121...
<dbl> 0.37, 0.35, 0.31, 0.32, 0.28, 0.26, 0.24, 0.21, 0.22, 0.25, 0.24, 0.24, ...
<dbl> 190, 189, 189, 189, 189, 189, 189, 189, 189, 189, 189, 189, 189, 189, 1...
<dbl> 38000, 38000, 40000, 43000, 44000, 46000, 48000, 49000, 50000, 52000, 5...
<dbl> 68.00, 63.00, 57.00, 58.00, 52.00, 47.00, 43.00, 39.00, 41.00, 45.00, 4...
<dbl> 68.00, 63.00, 57.00, 58.00, 51.00, 47.00, 43.00, 39.00, 40.00, 44.00, 4...
<dbl> 14000, 13000, 12000, 13000, 12000, 11000, 11000, 10000, 11000, 12000, 1...
<dbl> 14000, 13000, 12000, 13000, 12000, 12000, 11000, 10000, 11000, 12000, 1...
<dbl> 0.17, 0.30, 0.27, 0.29, 0.29, 0.31, 0.32, 0.33, 0.36, 0.41, 0.43, 0.47, ...
<dbl> 34, 61, 58, 66, 67, 75, 82, 85, 96, 110, 120, 140, 150, 160, 170, 160, ...
<dbl> 20130323, 20284311, 21378110, 22733047, 23560660, 24404569, 25424099, 2...
```

• 数据的含义如下：

字段名	类型	说明
基础标识字段	—	—
country	字符型	国家/地区名称
g_whoregion	字符型	所属WHO区域
iso_numeric	整型	ISO数字国家编码
iso2	字符型	ISO 2位国家编码
iso3	字符型	ISO 3位国家编码
year	整型	观测年份
病例检测与防控效果指标	—	—
c_cdr	浮点型	病例检出率（结核病治疗覆盖率），单位%
c_newinc_100k	浮点型	每10万人病例报告率（新发病例+复发病例）
cfr	浮点型	结核病病死率
发病率估算核心指标	—	—
e_inc_100k	浮点型	每10万人结核病发病率
e_inc_num	整型	结核病发病总人数估算值
死亡率估算核心指标	—	—
e_mort_100k	浮点型	每10万人结核病总死亡率
e_mort_num	浮点型	结核病死亡总人数估算值
e_mort_exc_tbhiv_100k	浮点型	非HIV相关结核病每10万人死亡率
e_mort_exc_tbhiv_num	浮点型	非HIV相关结核病死亡总人数

字段名	类型	说明
e_mort_tbhiv_100k	浮点型	HIV阳性人群结核病每10万人死亡率
e_mort_tbhiv_num	浮点型	HIV阳性人群结核病死亡总人数
人口基础指标	—	—
e_pop_num	整型	对应国家/地区当年估算总人口数

- 接下来，我们检查数据中的缺失值：

```
# 检查缺失值
colsums(is.na(tb))
...
country          g_whoregion      iso_numeric      iso2
0                0                0                0
iso3              year            c_cdr            c_newinc_100k
0                0                293            185
cfr              e_inc_100k        e_inc_num        e_mort_100k
128              0                0                24
e_mort_exc_tbhiv_100k e_mort_exc_tbhiv_num    e_mort_num    e_mort_tbhiv_100k
24              24                24            24
e_mort_tbhiv_num    e_pop_num
24              0
```

我们可以在具体分析的时候再根据分析条目做缺失值清理。

流行病学指标理解

- 因为我们之前都是在个体（患者）层面做数据分析，我们第一次接触宏观数据，所以先挑一些流行病学指标看一看。
- 发病计数（Incidence Count）与发病率（Incidence Rate）
 - （非常直观）发病计数是总共有多少病例（疾病负担的绝对规模），发病率是人群中患病比例，两者没有直接相关关系（左图：发病计数排名前十的国家年份；右图：发病率排名前十的国家年份）：

country			country		
<chr>	year	e_inc_num	<chr>	year	e_inc_100k
India	2005	3590000	Eswatini	2009	1590
India	2004	3580000	Eswatini	2010	1590
India	2006	3580000	Eswatini	2006	1460
India	2003	3550000	Eswatini	2007	1430
India	2007	3550000	Eswatini	2005	1420
India	2008	3520000	Eswatini	2008	1390
India	2002	3510000	Eswatini	2004	1320
India	2009	3470000	Eswatini	2011	1300
India	2001	3460000	Eswatini	2003	1270
India	2010	3430000	South Africa	2007	1270

- 这里，发病率是按照“per 100K”计算的，即每10万总人口中的病例数，这是在做人口层面的归一化。
- 死亡率（Mortality）与发病率
 - （同样非常直观）发病率高不一定代表死亡率高。发病高，不一定意味着治疗差；死亡高，也不一定只是因为病例多。

	country	year	Incidence	Mortality
1	China	2023	52.0	1.90
2	Germany	2023	4.8	0.35
3	India	2023	195.0	22.00
4	South Africa	2023	427.0	88.00
5	United States of America	2023	3.1	0.19

- 病死率（Case Fatality Rate）
 - CFR = deaths/cases，描述的是患病之后死亡的比例。

	country	year	incidence_per_100k	mortality_per_100k	cfr	calc_cfr	calc_cfr_pct
1	China	2023	52.0	1.90	0.04	0.03653846	3.65%
2	Germany	2023	4.8	0.35	0.07	0.07291667	7.29%
3	India	2023	195.0	22.00	0.12	0.11282051	11.28%
4	South Africa	2023	427.0	88.00	0.22	0.20608899	20.61%
5	United States of America	2023	3.1	0.19	0.06	0.06129032	6.13%

- 简单的公共卫生解释
 - 可以设想两个例子，并做简单的公共卫生解释：
 - 假设某个国家发病率很高，死亡率不算特别高，CFR 较低，可能意味着疾病传播广，但医疗系统较成熟，患者能够被较早诊断与治疗；
 - 假设某些国家发病率不一定最高，但 CFR 很高，则可能意味着诊断延迟、治疗获取受限，医疗资源短缺。

本节小结

- 这一小节我们检查了数据，并简单查看了几个流行病学相关的指标。在下一小节中，我们将检查结核病（Tuberculosis, TB）负担的空间分布与地区差异。

Step 2 全球 TB burden 的空间分布

- 在上一小节中，我们简单检查了若干国家的TB发病率、死亡率等统计结果，在这一小节中，我们将从国家层面的“个体”分析转移到全球层面的“系统”分析。
- 我们先按照国家组织分析对象，检查不同国家年平均TB发病率：

```
tb %>%
  group_by(country) %>%
  summarise(
    mean_incidence =
      mean(e_inc_100k, na.rm = TRUE)
  ) %>%
  arrange(desc(mean_incidence))
```


结果如下：

country	mean_incidence
<chr>	<dbl>
Eswatini	947.500000
South Africa	943.458333
Lesotho	930.416667
Namibia	830.125000
Philippines	555.625000
Gabon	547.166667
Central African Republic	540.000000
Democratic People's Republic of Korea	513.000000
Botswana	507.083333
Timor-Leste	498.000000

1-10 of 215 rows

我们猜想，国家之间的差异或许能上升到地区级别，即不同的地区发病率也会存在差异。

- 所以，我们接下来以地区为粒度进行发病率分析：




我们发现，非洲和东南亚地区的TB发病率要显著地高于其他地区。

- 我们进一步把这个TB发病率画到地图上！在这里，我们用到了 `maps` 和 `sf` 这两个包。

Global Tuberculosis Incidence

Estimated incidence per 100k population (2023)




- 我们发现，不同区域的TB发病率是有明显差异的，呈现出了某种区域模式：非洲、东南亚负担高，而欧洲/北美负担低。

- 我们可以把TB发病率改成发病人数：

Global Tuberculosis Incidence Count


Estimated number of incident TB cases (2023)




- 这张图和我们之前做数据理解时得到的结论一致。发病率和发病人数没有绝对的关联，发病人数多的国家发病率不一定高。
- 最后，我们就“为什么疾病负担会区域集中”的问题做一个简单的公共健康解释。TB 负担的区域集中，可能与医疗保健获取、贫困、营养、艾滋病毒流行率、监控系统等因素有关。
- 本节小结：在这一小节中，我们分析了全球 TB 负担的空间分布与地区差异。我们尝试了做地图可视化，利用地图与区域比较分析疾病负担的地理模式。我们产生了这样一种认识，TB 负担并不是均匀分布的，而是长期集中在某些国家与地区。我们尝试从空间分布与区域差异中提出公共健康解释，尝试用流行病学思维思考问题。😊

Step 3 TB 的时间趋势分析

- 在上一小节中，我们探索了全球 TB 负担的空间分布与地区差异，并做了地图可视化。然而，我们分析的对象只是某个固定时间点的 TB 负担。在这一节中，我们开始探索 TB 负担的时间变化趋势。我们可以提出很多问题，例如，TB 发病率是在下降还是上升？哪些国家改善最快？哪些地区长期停滞？
- 我们可以先从全球总体趋势入手，画出全球 TB 发病人数的变化趋势：




和 TB 死亡人数的变化趋势：



从这两张图中，我们可以做一些简单的分析（AI辅助生成的！）：

- 首先，从 2000 年到 2019 年，全球 TB 发病人数与死亡人数整体都呈下降趋势。这说明过去二十年中，全球 TB 防控总体是在改善的。但两者下降的幅度并不一样。发病人数下降相对缓慢，而死亡人数下降非常明显，几乎减半。这意味着，虽然仍然有很多人感染 TB，但死于 TB 的人数正在持续减少。这可能反映了全球治疗体系的改善，例如抗结核药物可及性提高、早期筛查能力增强、DOTS 等全球公共卫生项目推进、HIV/TB 联合治疗改善。
- 另一个非常值得注意的现象是 COVID-19 时期的变化。在发病人数图中，2020 年后出现了明显反弹，但死亡人数图中，波动相对较小，并且随后继续下降。这可能说明，疫情对 TB 的发现与报告系统影响较大，但对已有治疗体系的影响相对有限。
- 接下来，我们进入国家级别的趋势分析。我们挑选中国、南非、印度这三个国家，观察它们的 TB 发病率变化情况：



从这张图中，我们可以得出以下的趋势并作出解释（继续AI辅助分析！）：

- 首先，不同国家之间的 TB 负担差异非常明显。南非的发病率长期最高，在 2000-2010 年间甚至超过 1000/100k；印度处于中间水平；中国最低。这说明全球疾病负担并不是均匀分布的。
- 其次，三个国家的趋势形态也明显不同。中国呈现长期稳定下降，说明 TB 管控效果较持续，公共卫生体系相对稳定。印度也在下降，但速度更缓慢，近几年开始趋于平台化。南非的趋

势最特殊。它在 2000 年后先明显上升，随后又快速下降，形成了非常明显的倒 U 型趋势。

这一现象与南非长期存在严重 HIV/TB 共感染有关。HIV 流行会显著提高 TB 负担，而后期的快速下降，则可能与 HIV 治疗普及和 TB/HIV 联合防控改善有关。

- 最后，这张图也说明，即使全球总体趋势相同，不同国家的负担水平、变化速度和趋势形态仍然可能完全不同。因此，全球变化趋势往往会掩盖国家层级的异质性。
- 我们可以再强调一下 COVID-19 时期 TB 发病率的变化情况。如刚才的分析情况，从趋势图可以看到，2020 年之后，全球 TB 负担出现了明显波动，部分国家甚至出现反弹。这说明疫情不仅影响了新冠本身，也对原有的结核病防控体系造成了冲击。疫情期间，很多患者无法及时就医，结核病筛查和早期诊断受到影响，导致病例发现延迟。一些原本能够较早发现的患者，可能在更晚阶段才被诊断出来。同时，大量医疗资源被优先投入疫情防控，原本用于结核病的医护人员、检测能力和公共卫生资源受到挤占，影响了常规防控工作的开展。疫情还影响了疾病监测与数据报告系统。一些国家在疫情期间的统计和上报能力下降，因此部分年份的数据可能出现异常波动。此外，封锁和医疗系统压力也可能导致治疗中断，例如患者无法按时复诊、药物供应受影响等，从而进一步增加疾病负担。这反映了**数据趋势的变化，往往与现实世界中的重大事件密切相关**。
- 还需要强调的是，我们在这一小节做的时间趋势分析，只能说明时间关联。例如，发病率与死亡率下降，可能和医疗政策、监控、经济条件等因素改善有关，但**不能证明它们的因果性**。
- 本节小结：我们在这一小节中分析了 TB 的时间变化趋势。相比于之前围绕国家与空间分布的的分析，这一小节更关注疾病负担如何随着时间变化，并对不同国家与地区为什么会表现出不同的变化趋势进行了解释。同时，我们还关注了现实世界事件（Covid-19）对 TB 的影响。

Step 4 从疾病数量到疾病负担

- 在上一小节中，我们分析了 TB 发病人数、死亡人数的时间变化趋势。一个有一点反直觉的事情是，病例越多不一定就意味着国家的疾病负担（burden）越重。比如，有的国家病例很多，但死亡率不高；有的国家的发病率不算最高，但 CFR 很高。在这一小节中，我们会进一步理解之前已经提及了很多次的疾病负担。
- 如第一小节展示的，病例最多不一定意味着疾病负担最大，例如，印度的病例总数最高，但是印度的发病率、病死率却不是最高的，对印度来说，高病例数更多很可能只是他们的人口基数大。所以，我们不能简单地认为病例总数高就代表疾病负担大。
- 我们可以从疾病发病率、死亡率的角度来理解疾病负担。如果一个国家的疾病发病率高，这意味着疾病传播范围广、人群风险高，高的发病率更接近于传播负担高（transmission burden，这也是疾病负担的一部分）。死亡率则表明了疾病死亡负担的高低，它也可以反映出一个国家诊断延迟、治疗可及性、医疗质量、药品供应等医疗水平的高低。
 - 不要忘了我们项目的目的是了练习使用 R，而不是涉猎更多的领域：) 补充两段 R 代码的执行结果：
 - 2023年发病率排名前十的国家包括：

country<chr>	e_inc_100k<dbl>
Marshall Islands	692
Lesotho	664
Philippines	643
Myanmar	558
Central African Republic	540
Kiribati	533
Democratic People's Republic of Korea	513
Gabon	505
Timor-Leste	498
Mongolia	491


- 2023年死亡率排名前十的国家包括：

country<chr>	e_mort_100k<dbl>
Lesotho	229
Central African Republic	142
Gabon	139
Guinea-Bissau	122
Namibia	98
Myanmar	90
South Africa	88
Liberia	85
Congo	84
Eswatini	77

- 同时展示发病率与死亡率：

country<chr>	mean_incidence<dbl>	mean_mortality<dbl>
Afghanistan	188.041667	41.37500000
Albania	17.708333	0.44791667
Algeria	70.041667	7.82916667
American Samoa	6.595833	0.52250000
Andorra	9.079167	0.72291667
Angola	354.708333	83.87500000
Anguilla	21.833333	8.99166667
Antigua and Barbuda	4.462500	1.47916667
Argentina	28.708333	2.07916667
Armenia	52.250000	4.27500000

- 可以更进一步地通过病死率（CFR）来了解疾病负担。画出发病率和病死率的散点图，可以发现，某些国家的 TB 发病率很高，但 CFR 并不高；另外一些国家发病率不算最高，但 CFR 却明显更严重。从这里可以看出疾病频率（frequency）和疾病危害（severity）的区别，CFR 更贴近医疗结果一些。



- 这些疾病负担可以反映出一个国家的医疗水平。某些国家的疾病发病率很高，死亡率较低，CFR 较低，可能意味着这个国家的诊断系统较成熟、治疗可及性较好、医疗干预有效；反之，另一些国家的疾病发病率不一定最高，但死亡率与 CFR 较高，这可能意味着这个国家医疗资源短缺、存在治疗中断、诊断延迟等情况。
- 上述的分析表明，疾病负担是一个多维的变量，它同时包含了传播（transmission）、人群风险（population risk）、致死（mortality）、医疗结果（healthcare outcome）等多个层面。
- 本节小结：在这一小节中，我们进一步理解了“疾病负担”这个概念，它是一个多维的概念，在描述疾病负担时，需要从多个角度进行分析。

Step 5 HIV、人口与 TB 风险模式

- 在上一小节中，我们探索了疾病负担的多个维度。疾病不仅是一种生理物理现象，与社会也有非常紧密的联系，例如，HIV 感染率较高的地区，TB 负担往往也更严重；医疗资源有限的地区，死亡率与病死率可能更高；营养、贫困与卫生条件，也会影响疾病传播。在这一小节中，我们将考虑疾病之间的相互作用与社会决定因素。
- 在第一节中，我们观察到数据集中有一个 `e_mort_tbhiv_100k` 变量，这个变量的含义是“HIV阳性人群结核病每10万人死亡率”，它启发我们，TB 和 HIV 之间可能会有一定关联。比如，我们可以检查哪些地区和HIV关联的 TB 死亡率更高：

<code>g_whoregion</code> <chr>	<code>hiv_tb_mortality</code> <dbl>
Africa	46.4354342
Americas	1.0989245
Eastern Mediterranean	1.3148295
Europe	0.3546501
South-East Asia	4.1304206
Western Pacific	0.7885473

我们发现，非洲地区的 HIV 相关 TB 死亡率要显著地高于其他地区。HIV 和 TB 相关是可以理解的，HIV 会削弱免疫系统，从而增加 TB 的进展风险。

- 我们还可以检查非 HIV 相关的 TB 死亡率与 HIV 相关的 TB 死亡率之间的关系：

g_whoregion <chr>	tb_mortality <dbl>	hiv_tb_mortality <dbl>	non_hiv_tb_mortality <dbl>
Africa	81.431853	46.4354342	34.990501
Americas	4.220519	1.0989245	3.044368
Eastern Mediterranean	12.269034	1.3148295	10.955473
Europe	4.012955	0.3546501	3.569813
South-East Asia	46.914626	4.1304206	42.671589
Western Pacific	14.016227	0.7885473	13.192658

我们发现，在非洲地区，HIV 显著地加大了 TB 死亡率。

- 从这个HIV-相关 TB 死亡率地区分布模式，我们可以看出，疾病负担与社会环境很可能有关。这很好理解：疾病负担的差异并不仅仅来源于病原体本身，还和贫困、营养条件、医疗保健可及性、居住密度、卫生设施、监控质量等等很多因素有关。TB 负担很可能长期集中在某些资源有限地区。
- 这里涉及到一个“生态谬误”(Ecological Fallacy) 的概念，比如，某些国家 HIV 相关 TB 死亡率高，并不能直接推出每一个 HIV 患者都会面临更高风险，这是因为国家级的统计模式和个体层面的机制不在同一个层次。生态谬误指的就是用人群水平的相关去解释个体层面的因果。
- 应该意识到，Proj 04用到的数据还存在一定局限性，比如，有的国家可能检测能力不足、报告系统不完整，因此数据中的低发病率不一定真意味着疾病负担低。
- 此外，公共健康分析很难找到某种正确答案，疾病负担本来就是生理、社会、经济等条件共同作用的结果。公共健康分析更多是在理解复杂现实，而不是找到唯一原因。
- 本节小结：在这一小节中，我们接触了疾病之间的相互作用，与社会环境对疾病负担的影响。我们应该产生这种印象，公共健康分析的核心，并不是寻找单一原因，而是尝试理解疾病如何在人群、社会环境与医疗系统中共同作用。

Step 6 把公共卫生分析组织成研究故事

- 在前面几小节里，我们接触了发病率与死亡率、发病人数与人群风险、时间趋势、地区差异、疾病负担、疾病相互作用与社会影响等方面的内容，在这一小节里，我们将关注怎么把这些分析组织成一个完整的公共健康故事。
- 公共健康故事需要一定的叙事结构，通常的思路是，描述疾病负担 -> 发现疾病模式 -> 分析疾病趋势 -> 提出解释 -> 讨论局限性，这也是 Proj 04 的组织顺序：我们先发现 TB 负担在全球分布不均，然后进一步观察某些地区长期负担更高，再进一步，发现不同国家趋势不同，最后关注到 HIV、医疗资源与社会环境可能影响疾病负担。需要再次强调的是，我们做的公共健康分析只是根据数据提出合理的猜想和解释，它并不是最终因果结论。

项目总结

在这个项目中，我们关注的对象变成了国家、地区、人群以及时间趋势。我们接触了流行病学中的核心指标，包括发病率、死亡率、病死率。我们逐渐发现，疾病负担并不是单一数字，而是发病、死亡、人口规模、医疗资源以及社会环境共同作用的结果。